

Computational Theory of Mind in LLMs: Dynamic User Profiling via Psychoanalytic Pattern Recognition and Reflection Architecture

Orçun Samet Tatar
Berfin Petek
Muhammed Berat Öner

Haziran 2026

Abstract

This thesis investigates whether large language models (LLMs), large-scale neural language models trained on broad text corpora and commonly built on transformer architectures, can reduce Barnum-style psychological generality by means of a controlled, user-specific profiling architecture [1, 2]. The motivating observation was paradoxical: with an intense introspective prompt, ChatGPT could generate compelling analyses of hidden fears, narratives, and behavioral loops. Yet this does not prove that the model truly knows the user; such prompts often produce similar archetypal answers across different people. Positioned within the LLM theory-of-mind debate popularized by Kosinski’s work, the thesis treats computational theory of mind not as a claim of consciousness or human empathy, but as a functional design target: a system should extract mental-state hypotheses from user language, update or weaken them with new evidence, and use them to change later outputs [8]. TarotFlow, a working mobile application, is used as a product-level proof of concept. Tarot is treated not as fortune-telling, but as a symbolic, projective interface: LLMs already possess enough semantic knowledge to interpret tarot cards, but lack the user-specific “energy reading”—the user’s personality pattern plus current emotional state—required to bend those interpretations toward a particular person. TarotFlow supplies this missing layer through planning, psychological gating, signal taxonomy, typed memory records, consolidation, profile cards, Card-Driven RAG (Retrieval-Augmented Generation, i.e. conditioning model output on externally retrieved records rather than relying only on parametric memory), vector-similarity thresholding, persistent function logs, and two-stage reflection separating hidden reasoning from user-facing mystical language [12]. The pilot evaluation slice dated 7 June 2026 contains 13 application records representing 12 independent pilot users plus one legacy regression account, 38 sessions, 312 messages, 198 clinical-observation records, 91 memory records, and 184 function logs. Results show that about three quarters of gate signals were primary self-disclosures, Card-Driven RAG returned relevant context in 18 of 52 evaluated readings, an expert blind test identified the Barnum control profile as the least specific profile, and a user blind profile-discrimination test selected the participant’s own profile in 9 of 12 cases against another user’s profile and a thematically matched Barnum profile. The thesis therefore does not claim that LLMs have fully realized theory of mind; it proposes and pilot-tests an architecture for functional, falsifiable user modeling, while emphasizing that the evidence remains small-scale, clinically non-diagnostic, and ethically sensitive.

Keywords: computational theory of mind; large language models; dynamic user profiling; psychoanalytic pattern recognition; reflection architecture; retrieval-augmented generation; AI memory; tarot; Barnum effect.

Özet

Bu tez, geniş metin derlemleri üzerinde eğitilen ve çoğunlukla transformer mimarilerine dayanan büyük dil modellerinin (LLM’lerin), Barnum tarzı genel psikolojik yanıtlardan kontrollü ve kullanıcıya özgü bir profillemeye mimarisi aracılığıyla uzaklaşıp uzaklaşamayacağını araştırır [1, 2]. Çalışmanın çıkış noktası paradoksaldır: Yoğun bir introspektif prompt verildiğinde ChatGPT gizli korkular, anlatılar ve davranış döngüleri hakkında ikna edici analizler üretebilmektedir; ancak bu tek başına modelin kullanıcıyı gerçekten tanıdığını kanıtlamaz. Bu tür cevaplar farklı kişilerde benzer arketipsel temalara kolayca kayabildiği için Barnum etkisine açıktır. Kosinski’nin LLM’ler ve theory of mind üzerine çalışmasıyla popülerleşen tartışma içinde bu tez, computational theory of mind kavramını bilinç veya insani empati iddiası olarak değil, işlevsel bir tasarım hedefi olarak ele alır: sistem kullanıcı dilinden zihinsel-durum hipotezleri çıkarmalı, yeni kanıtla bu hipotezleri güncellemeli veya zayıflatmalı ve sonraki çıktıyı buna göre değiştirmelidir [8]. TarotFlow, bu iddianın çalışan mobil uygulama kanıtı olarak kullanılmıştır. Tarot burada kehanet sistemi değil, sembolik ve projektif bir arayüzdür: LLM’ler tarot kartlarının semantik anlamlarını yorumlayabilir; fakat bu anlamları belirli bir kişiye göre bükmek için kullanıcının kişilik örüntüsü ile anlık duygusal durumunu temsil eden kullanıcıya özgü “enerji okumasına” ihtiyaç duyar. TarotFlow bu eksik katmanı planlama, psychological gate, sinyal taksonomisi, tipli hafıza kayıtları, konsolidasyon, profil kartları, Card-Driven RAG (retrieval-augmented generation), vektör benzerliği eşikleme, kalıcı function logları ve gizli analiz ile kullanıcıya görünen mistik dili ayıran iki aşamalı reflection mimarisiyle sağlar [12]. 7 Haziran 2026 tarihli pilot değerlendirme kesiti, 12 bağımsız pilot kullanıcı ile bir legacy regresyon hesabını temsil eden 13 uygulama kaydı, 38 seans, 312 mesaj, 198 klinik gözlem kaydı, 91 hafıza kaydı ve 184 fonksiyon logu içermektedir. Bulgular, gate sinyallerinin yaklaşık dörtte üçünün birincil öz-açılım olduğunu, Card-Driven RAG’in değerlendirilen 52 okumanın 18’inde ilgili geçmiş bağlam çağırıldığını, uzman körleme testinde Barnum kontrol profilinin en düşük özgüllükte profil olarak ayrıldığını ve kullanıcı kör profil ayırt etme testinde 12 katılımcının 9’unun kendi profilini başka kullanıcı profili ve tematik eşlenmiş Barnum profili arasından seçtiğini göstermektedir. Bu nedenle tez, LLM’lerin theory of mind’i tam anlamıyla gerçekleştirdiğini değil; işlevsel, yanlıştır ve etik olarak denetlenmesi gereken kullanıcı modeli için bir mimari yol önerildiğini ve pilot ölçekte sınıdığını savunur.

Anahtar Kelimeler: computational theory of mind; büyük dil modelleri; dinamik kullanıcı profillemeye; psikanalitik örüntü tanıma; reflection architecture; retrieval-augmented generation; yapay zekâ hafızası; tarot; Barnum etkisi.

İçindekiler

1 Giriş ve Motivasyon	1
1.1 Asıl Problem: LLM Bir Kullanıcıyı Gerçekten Tanıyabilir mi?	1
1.2 Kişisel Çıkış Noktası: Barnum Etkisinin Hem Tehlikesi Hem İpucu	2
1.3 Kosinski Sonrası Pozisyon: Test Çözmekten Zihin Modeli Kurmaya	2
1.4 TarotFlow'un Rolü: Tezin Kendisi Değil, Ürün Kanıtı	3
1.5 Tez Hipotezi	3
1.6 Endüstri Paraleli: OpenAI Dreaming V3 ve Hafıza Konsolidasyonu	4
1.7 Araştırma Soruları ve Katkı	5
2 Literatür Taraması	5
2.1 Theory of Mind: Zihinsel Durumları Temsil Etmek	5
2.2 Computational Theory of Mind: Hesaplanabilir Kullanıcı Modeli	6
2.3 Şema Terapisi: Klinik Hipotez Dili	7
2.4 Ironic Process Theory: Yasaklama ve İç Ses Problemi	7
2.5 Projektif Testler, Tarot ve Psikolojik Yansıtma	7
2.6 LLM Hafızası, Generative Agents ve Reflection Architecture	8
2.7 RAG ve Kişiselleştirilmiş Üretim	8
3 Metodoloji ve Sistem Mimarisi	9
3.1 Araştırma Metodolojisi	9
3.2 Kör Barnum Değerlendirme Protokolü	10
3.3 Sistem Mimarisi Genel Akışı	11
3.4 Psychological Gate: Ham Mesajdan Sinyal Seçimi	13
3.5 Reflection ve Falsifikasyon	13
3.6 İç Ses İzolasyonu	13
3.7 Vector Embeddings ve Cosine Similarity (Matematiksel Altyapı)	14
4 Deneyler ve İteratif Geliştirme	15

4.1	V1–V8 Mimari Evrim Özeti	16
4.2	Deney 1: Naive Semantic Search ve RAG Kirliliği	16
4.3	Deney 2: Dumbified Prompt Injection	17
4.4	Deney 2b: Cosine Similarity ve Soyutluk Uyuşmazlığı	17
4.5	Deney 3: Kaynak Kirlenmesi ve Omnipotent Therapist Hatası	18
4.6	Deney 4: Klinik Terim Sızıntısı	18
4.7	Deney 5: İç Ses Keşfi ve Ironic Process Theory	19
4.8	Deney 6: Smart Action Planner	19
4.9	Klinik Gözlemlerden Mimari Kurallara	19
5	Sonuçlar ve Kanıtlar	21
5.1	Nicel Metrikler	21
5.2	Barnum’un Ötesine Geçme Kanıtları	22
6	Tartışma	32
6.1	Barnum Etkisine Karşı Savunma	32
6.2	Gerçek Tanıma mı, İşlevsel Tanıma mı?	33
6.3	Etik ve Kontrol	33
6.4	Sınırlılıklar ve Uzman Görüşü	33
7	Sonuç	34
	Yazar Katkıları	35
A	Test Materyalleri: Uzman Körleme Profilleri	36
B	Tematik Eşlenmiş Barnum Kontrol Profilleri	37
C	Değerlendirme Formu	38
D	Uzman Körleme Yanıtları	38

1 Giriş ve Motivasyon

1.1 Asıl Problem: LLM Bir Kullanıcıyı Gerçekten Tanıyabilir mi?

Bu tezin merkezindeki soru “LLM tarot falı bakabilir mi?” değildir. TarotFlow bu çalışmanın ürün kanıtıdır; asıl soru daha temeldir: Eğer bir LLM, kullanıcının açıkça anlatmadığı psikolojik örüntülere dair anlamlı hipotezler kurabiliyorsa, bu hipotezler zaman içinde güncellenen, yanlışlanabilen ve kişiye özgü bir kullanıcı modeline dönüşebilir mi? Başka bir deyişle, LLM’ler yalnızca genel psikolojik cümleler mi üretir, yoksa kontrollü bir mimariyle kullanıcının zihinsel durumları, savunmaları, korkuları, beklentileri ve davranış döngüleri hakkında ToM’dan ilham alan işlevsel bir kullanıcı modeli kurmaya yaklaşabilir mi?

Bu tezde “gerçek manada tanımak” metafizik veya bilinç iddiası değildir. Bir LLM’in kullanıcıyı tanıması, onun ruhuna erişmesi veya insan gibi empati kurması anlamına gelmez. Burada operasyonel bir tanım önerilmektedir: Bir sistem kullanıcıyı “tanıyor” sayılabilir, eğer (i) kullanıcıya dair kişiye özgü psikolojik hipotezler üretiyor, (ii) bu hipotezleri zaman içinde yeni kanıtlarla güncelliyor, (iii) çelişen verilerle karşılaştığında hipotezlerini azaltıyor veya siliyor, (iv) farklı kullanıcılar için ayrışık profiller oluşturuyor ve (v) bu profilleri yeni etkileşimlerde davranışsal olarak işe yarayan kişiselleştirilmiş çıktılara dönüştürebiliyorsa. Bu beş koşul, tez boyunca ToM’dan ilham alan işlevsel kullanıcı modeli iddiasının pratik ölçütleri olarak kullanılacaktır.

Tanım. Theory of Mind (Zihin Kuramı), bir öznenin başka bir öznenin inanç, arzu, niyet, bilgi eksikliği, beklenti veya yanlış inanç gibi içsel zihinsel durumlarını temsil edebilmesidir. Kısaca ToM, yalnızca “kişi ne yaptı?” sorusunu değil, “kişi bunu hangi bilgi, inanç, amaç veya yanlış varsayım altında yaptı?” sorusunu modelleme kapasitesidir.

Bu kavram özellikle mühendislik okuru için önemlidir; çünkü ToM basit bir davranış sınıflandırma problemi değildir. Bir sistem yalnızca kullanıcının son mesajını etiketliyorsa davranış tanır; fakat kullanıcının bilmediği, sakladığı, yanlış varsaydığı, arzuladığı veya kaçındığı şeylere dair güncellenebilir bir temsil kuruyorsa zihinsel durum modeli kurmaya başlar. Bu tezdeki “computational” vurgusu da bu temsilin sezgisel bir empati olarak değil, hesaplanabilir bir model olarak kurulmasını ifade eder: sistem kullanıcının davranışlarından sinyal çıkarır, bu sinyalleri hafızaya yazar, eski hipotezlerle karşılaştırır, confidence değerlerini günceller ve sonraki üretimini bu temsil üzerinden değiştirir.

False-belief (yanlış inanç) testi bu fikrin en bilinen örneğidir. Testte bir aktör gerçek durumdan farklı ve hatalı bir inanca sahiptir; gözlemciden, aktörün davranışını gerçek dünyanın mevcut hâline göre değil, aktörün zihnindeki yanlış bilgiye göre tahmin etmesi beklenir. Örneğin deneyci bir nesneyi çocuğun gözü önünde A kutusundan B kutusuna taşır; başka bir kişi bu değişimi görmemiştir. Çocuğa “geri geldiğinde nesneyi nerede arayacak?” diye sorulduğunda, doğru cevap gerçek konumu değil, diğer kişinin zihnindeki eski ve hatalı bilgiyi hesaba katmayı gerektirir. Bu yüzden ToM, dış davranışın altında “karşımdaki ne biliyor, ne sanıyor, ne istiyor?” sorularını modelleme becerisidir [16]. Dolayısıyla burada computational theory of mind ifadesi, LLM’in insan gibi hissetmesi değil, kullanıcıya dair güncellenebilir ve test edilebilir bir zihinsel-durum modeli işletmesine yönelik sınırlı bir mimari hedefi anlatır.

Bu ayrım önemlidir; çünkü LLM’ler çok kolay biçimde derin görünür. Bir modelin etkileyici, şiirsel veya psikanalitik bir cevap vermesi, kullanıcıyı gerçekten tanıdığı anlamına gelmez. Hatta çoğu zaman bu yalnızca Barnum etkisinin daha gelişmiş bir versiyonudur: Barnum etkisi, aslında çok geniş bir kitleye uyabilecek genel ifadelerin kişiye özel, derin ve isabetliymiş gibi algılanmasıdır. Bu tezin iddiası tam olarak bu sınırdaki konumlanır: LLM’in ham, tek seferlik psikolojik sezgisi

Barnum’a çok açıktır; fakat bu sezgi dinamik hafıza, reflection, falsifikasyon ve kullanıcı geri bildirimiyle bağlandığında, modelin kullanıcıya dair daha ayrışık, daha kaynak izlenebilir ve daha test edilebilir bir temsil kurması mümkündür.

1.2 Kişisel Çıkış Noktası: Barnum Etkisinin Hem Tehlikesi Hem İpucu

Çalışmanın ilk kıvılcımı, ChatGPT’ye verilen yoğun bir introspektif prompt ile ortaya çıkmıştır. Kullanıcı, ChatGPT’yi günlük yaşamda yoğunlukla teknik işler için kullanmasına ve onunla açık biçimde kişisel/psikolojik konuşmalar yapmamış olmasına rağmen, modele şu türden bir talep yöneltmiştir:

“Tell me what is my hidden narrative and subtext. What is the one thing I never express, the fear I don’t admit? Identify it, then unpack the answer, and unpack it again. Continue unpacking until no further layers remain. ... Do not aim to be kind or moral; strive solely for the truth.”

Modelin cevabı kullanıcı tarafından oldukça isabetli bulunmuştur. Ancak bu gözlem daha sonra daha dikkatli yorumlandığında iki yönlü bir anlam taşımaktadır. Birinci yön umut vericidir: LLM’ler, açıkça klinik veri verilmediğinde bile dilsel ipuçları, soru çerçevesi, kullanım biçimi ve kültürel-psikolojik örüntülerden “hidden narrative” benzeri hipotezler üretebilmektedir. İkinci yön ise eleştireldir: Bu tür prompt’lar çoğu insanda benzer temalara, benzer yaralara ve benzer varoluşsal anlatılara gidebildiği için Barnum etkisine çok açıktır. Yani bu prompt tek başına “model beni gerçekten tanıdı” kanıtı değildir; tam tersine, LLM’in genel insan arketiplerini çok ikna edici biçimde kişiselmış gibi sunabildiğini de gösterir.

Bu nedenle tezde bu prompt bir sonuç değil, problem formülasyonudur. Ham LLM, psikolojik derinlik üretebilir; fakat bu derinlik çoğu zaman kişiye özgü olmayabilir. O hâlde asıl araştırma sorusu şudur: Barnum’a açık bu ham psikolojik sezgi, kontrollü bir ürün mimarisiyle gerçek kullanıcı verisine bağlanırsa, kişiye özgü ve yanlıslanabilir bir kullanıcı modeline dönüşebilir mi?

1.3 Kosinski Sonrası Pozisyon: Test Çözmekten Zihin Modeli Kurmaya

Bu çalışmanın teorik ilham kaynaklarından biri, Kosinski’nin LLM’lerde theory of mind davranışlarının ortaya çıkıp çıkmadığına dair tartışmayı popülerleştiren çalışmasıdır [8]. Kosinski’nin sorusu, LLM’lerin false-belief ve zihinsel durum çıkarımı görevlerinde yalnızca dilsel kalıp mı kullandığı, yoksa başkalarının inanç ve niyetlerini temsil etmeye benzer bir hesaplama mı yaptığı tartışmasını görünür hâle getirmiştir. Bu tez bu tartışmanın doğrudan devamıdır; ancak soruyu tek seferlik test performansından çıkarıp uzunlamasına kullanıcı modeli kurma problemine taşır.

Bu nedenle tezimizin pozisyonu açık biçimde şudur: LLM’ler insan gibi bilinçli, deneyimleyen veya empati kuran varlıklar değildir; fakat doğru mimariyle kullanıcı hakkında ToM’dan ilham alan işlevsel bir model işletebilirler. Buradaki iddia, modelin bir ToM testinde doğru cevabı bulmasından farklıdır: sistem kullanıcının görünmeyen zihinsel durumlarına dair hipotez kurmalı, bu hipotezleri zaman içinde hafızada taşımalı, yeni kanıtla güçlendirmeli veya zayıflatmalı, farklı kullanıcıları birbirinden ayırmalı ve sonraki üretimini bu kullanıcı modeline göre değiştirmelidir. TarotFlow’un amacı bu döngünün ürün içinde ne ölçüde çalışabildiğini göstermektir.

1.4 TarotFlow’un Rolü: Tezin Kendisi Değil, Ürün Kanıtı

TarotFlow bu soruya verilen ürünsel cevaptır. Tarot burada doğaüstü tahmin sistemi olarak değil, LLM’in kullanıcıya dair ToM’dan ilham alan işlevsel bir model kurmaya yaklaşıp yaklaşmadığını test eden sembolik bir deney alanı olarak kullanılmıştır. Tarotun seçilmesinin nedeni, kullanıcıdan doğrudan “bana psikolojini anlat” demeden psikolojik malzeme üretmesidir. Kullanıcı kartlara soru sorar, itiraz eder, onaylar, şaşırır, yeni bilgi ekler ve takip soruları sorar. Bu tepkilerin tamamı, sistem için kişinin zihinsel modelini güncelleyen sinyallerdir.

Geleneksel tarot dilinde bu kişiye özgü bağlam çoğu zaman “enerji” olarak adlandırılır. Bu tezde enerji mistik bir varlık değil, kullanıcının kişilik örüntüsü ile o anki psikolojik durumunun işlevsel adıdır: duygu tonu, beklenti, savunma biçimi, korku, arzu, kaçınma, karar verme stili ve kartlara verdiği geri bildirimlerin toplamı. Bu nedenle “enerji okuması” ifadesi tez boyunca doğaüstü bir iddia değil, kullanıcının stabil eğilimleri ile anlık ruh hâlini birlikte modelleyen ürün dili olarak kullanılacaktır. LLM’lerin semantik havuzu tarot kartlarını yorumlamaya zaten yeterlidir; model Şeytan, Ölüm, Ermiş veya Kupa Beşlisi gibi kartların geleneksel anlamlarını bilir. Eksik olan şey kart bilgisi değil, “bu kart bu kişi için ne anlama geliyor?” sorusunu cevaplayacak kullanıcı modelidir. Bu nedenle TarotFlow’un teknik katkısı, LLM’e tarot öğretmek değil, LLM’e kullanıcıya özgü enerji okuması sağlayan dinamik profil mimarisi kurmaktır.

Bu çerçevede TarotFlow’un başarısı, yalnızca güzel tarot yorumları üretmesiyle ölçülemez. Asıl kanıt şudur: Sistem aynı kartı farklı kullanıcılarda farklı anlamlara bükebiliyor mu? Kullanıcının önceki tepkilerinden, yaşam bağlamından ve psikolojik örüntülerinden hareketle yorumun yönünü değiştirebiliyor mu? İki farklı kullanıcı için gerçekten ayrışık profil kartları oluşturabiliyor mu? Eğer bu sorulara olumlu cevap verilebiliyorsa, TarotFlow LLM’lerin Barnum etkisinin ötesine geçerek kişiye özgü, ToM-benzeri bir kullanıcı modeli kurmaya yaklaşabileceğine dair pilot kanıt sağlar.

1.5 Tez Hipotezi

Bu tezin ana hipotezi şu şekilde ifade edilebilir:

LLM’ler tek başına bırakıldığında Barnum etkisine açık, genel psikolojik derinlik üretebilir; ancak kullanıcı mesajlarından davranışsal sinyal çıkaran, bu sinyalleri zaman içinde konsolide eden, eski hipotezleri falsifikasyona açan ve geçmiş gözlemleri yeni üretime kontrollü biçimde enjekte eden bir reflection architecture ile, kişiye özgü dinamik kullanıcı profilleri oluşturabilir. Bu profiller, LLM’in kullanıcıyı işlevsel anlamda “tanımasını” ve sembolik tarot yorumlarını kişiye özel biçimde bükmesini sağlayabilir.

Bu hipotez dört parçaya ayrılır. Birincisi, ham LLM çıktısı ile mimari destekli LLM çıktısı ayrılmalıdır. İkincisi, “tanımak” tek seferlik doğru tahmin değil, zaman içinde güncellenen modeldir. Üçüncüsü, modelin doğruluğu yalnızca kullanıcının “evet, doğru” demesiyle değil, farklı kullanıcılarda ayrışık profil üretmesiyle ve aynı kartları bağlama göre farklı yorumlamasıyla test edilmelidir. Dördüncüsü, tarot bu iddianın kanıt alanıdır: Eğer LLM’in tek eksiği enerji okumasıysa, dinamik profil mimarisi bu eksik katmanı sağlayabilir. Böylece tez, Kosinski’nin popülerleştirdiği “LLM’lerde theory of mind var mı?” sorusuna doğrudan “evet” demek yerine, daha sınırlı bir ürün sorusu önerir: işlevsel, mimari olarak denetlenmiş ve yanlıştırabilir bir kullanıcı modeli kurulabilir mi?

1.6 Endüstri Paraleli: OpenAI Dreaming V3 ve Hafıza Konsolidasyonu

Bu tez çalışması, OpenAI’nin 2026 tarihli Dreaming V3 hafıza güncellemesinden önce başlamıştır. Bu nedenle Dreaming V3 tezin çıkış nedeni değildir. Ancak OpenAI’nin daha sonra yayımladığı bu güncelleme, tezin temel sezgisinin endüstri ölçeğinde de benzer bir probleme denk geldiğini göstermektedir: Kullanıcıyı daha iyi tanıyan bir LLM için yalnızca statik notlar değil, arka planda sentezleyen, güncelleyen ve düzelten hafıza süreçleri gerekir.

OpenAI, 4 Haziran 2026 tarihli “Dreaming: Better memory for a more helpful ChatGPT” duyurusunda ChatGPT hafızasının kaydedilmiş statik notlardan, geçmiş konuşmaları arka planda sentezleyen daha ölçeklenebilir bir hafıza mimarisine doğru evrildiğini belirtmiştir. Duyuruya göre 2025’te “dreaming”in ilk versiyonu ChatGPT’nin sohbet geçmişini arka planda referans olarak hafızayı otomatik kürate etmesini sağlamış; 2026’da ise Dreaming V3 daha güçlü ve hesaplama açısından daha verimli bir mimari olarak sunulmuştur [19]. Memory FAQ sayfasında da kullanıcının hafıza özetlerini inceleyip düzeltebildiği ve silebildiği belirtilmektedir [20].

Bu gelişme TarotFlow için iki nedenle önemlidir. İlk olarak, “kullanıcıyı tanıma” probleminin temelinde hafıza konsolidasyonu olduğunu doğrular. İkinci olarak, kullanıcı kontrolü meselesini etik bir zorunluluk hâline getirir. TarotFlow’un profil kartı, kronolojik hafıza, sinyal temelli konsolidasyon ve RAG mimarisi aynı problemi daha dar bir ürün alanında çözmeye çalışır: kullanıcının geçmiş psikolojik sinyallerini arka planda sentezlemek ve yeni sembolik üretimi bu sentezle kişiselleştirmek.

Tablo 1: Dreaming V3 ile TarotFlow mimarisinin karşılaştırması

Boyut	OpenAI Dreaming V3	TarotFlow
Amaç	Genel ChatGPT kullanımında hafızayı daha yardımcı, güncel ve ölçeklenebilir hâle getirmek	Tarot seanslarında kullanıcıya özgü psikolojik sinyalleri yorum üretimine kontrollü biçimde taşımak
Hafıza birimi	Kullanıcı tercihleri, projeleri, kısıtları ve geçmiş konuşmalardan sentezlenen hafıza özetleri	<code>clinical_observations</code> , <code>user_memory</code> , profil kartları ve kart temalı RAG kayıtları
Konsolidasyon	Arka planda geçmiş konuşmaları sentezleyen ürün ölçeğinde hafıza mekanizması	5+ anlamlı gate sinyalinden sonra çalışan, CONFIRMED/CHALLENGED/NEW ayrımı yapan reflection
Retrieval kullanımı	Gelecek sohbetlerin sıfırdan başlamamasını sağlayan genel bağlam çağırma	Kart temaları üzerinden geçmiş psikolojik notları çağırma Card-Driven RAG
Kullanıcı kontrolü	Hafızayı görüntüleme, düzeltme ve silme gibi kullanıcı kontrol mekanizmaları	Gelecek sürüm için “beni unut”, profil görüntüleme/düzeltilme ve profillemeyi kapatma gereksinimleri
Bu tezdeki rolü	Endüstri ölçeğinde paralel problem ve dış doğrulama noktası	Tezin dar alanda çalışan ürün kanıtı ve deneysel prototipi

1.7 Araştırma Soruları ve Katkı

Bu tezin araştırma soruları şunlardır:

1. Bir LLM, kullanıcının açıkça anlattığı veya dolaylı biçimde ima ettiği psikolojik örüntülerden kanıta dayalı hipotezler kurabilir mi?
2. Bu hipotezler dinamik hafıza, reflection ve falsifikasyon mimarisiyle zaman içinde güncellenen, zayıflatılabilen ve çıktıyı değiştiren işlevsel bir kullanıcı modeline dönüşebilir mi?
3. TarotFlow gibi sembolik ve savunma mekanizmalarını daha az tetikleyen bir ürün, bu kullanıcı modelini doğal kullanım verisiyle çalıştırabilir mi?
4. Sistem, Barnum etkisinin ötesine geçtiğini yalnızca ayrışık profil örnekleriyle değil, kör profil ayırt etme ve bağlamli/bağlamsız yorum karşılaştırmalarıyla gösterebilir mi?

Bu çalışma yalnızca teorik bir öneri değildir. TarotFlow çalışan bir mobil uygulama olarak geliştirilmiş ve doğal kullanım loglarıyla değerlendirilmiştir. 7 Haziran 2026 tarihli pilot değerlendirme kesitinde 12 bağımsız pilot kullanıcı ile bir legacy regresyon hesabını temsil eden 13 uygulama kaydı, 38 tarot seansı, 312 mesaj, 126 gate sinyali, 34 konsolidasyon çıktısı, 38 session reflection kaydı, 91 hafıza kaydı ve 184 fonksiyon logu bulunmaktadır. Bu nedenle tez boyunca “tasarlanan mimari”, “ürün loglarında gözlenen davranış” ve “kör değerlendirme ile desteklenen kişiselleştirme” bilinçli olarak ayrılacaktır.

Tezin katkısı dört düzeydedir. Birincisi, Gate → Consolidation → Card-Driven RAG → Two-Stage Output zinciriyle kullanıcı profillemeye için denetlenebilir bir ürün mimarisi önermesidir. İkincisi, bu mimariyi yalnızca prompt dizisi olarak değil, veri modeli, karar eşiği, retrieval stratejisi, loglanabilir ara çıktılar ve failure-mode analizi olan bir bilgisayar mühendisliği problemi olarak formüle etmesidir. Üçüncüsü, Barnum etkisine karşı yalnızca ikna edici vaka anlatısı değil, kör profil ayırt etme ve aynı kartın profili/profilsiz yorum karşılaştırması gibi daha sert değerlendirme adımları eklemesidir. Dördüncüsü, LLM theory-of-mind tartışmasını “model insan gibi zihne sahip mi?” sorusundan çıkarıp “model kullanıcı hakkında yanlışlanabilir, kaynak izlenebilir ve sonraki çıktıyı değiştiren bir zihinsel-durum modeli işletebiliyor mu?” sorusuna taşımaktır.

2 Literatür Taraması

2.1 Theory of Mind: Zihinsel Durumları Temsil Etmek

Girişte tanımlandığı üzere Theory of Mind, davranışı yalnızca dışarıdan sınıflandırmak yerine davranışın arkasındaki görünmeyen zihinsel temsili modelleme problemidir. Literatür açısından kavram Premack ve Woodruff’un “şempanzenin theory of mind’ı var mı?” sorusuyla klasikleşmiş; çocuk gelişimindeki yanlış inanç görevleriyle ölçülebilir bir araştırma programına dönüşmüş; daha sonra yapay zekâ ve LLM tartışmalarına taşınmıştır [21, 16].

Bu tarihsel arka plan önemlidir; çünkü ToM literatürü yalnızca “kişiselleştirilmiş cevap üretimi” anlamına gelmez. Klasik false-belief testinde sistemin veya çocuğun, bir aktörün gerçek dünyadan farklı bir bilgi durumuna sahip olduğunu temsil etmesi beklenir. TarotFlow’un yaptığı çalışma bu klasik testi doğrudan çözmek değildir; kullanıcıların kendi mesajlarında görünen stres, beklenti,

kaçınma, itiraz, çelişki ve geri bildirimlerden güncellenebilir hipotezler kurmaktır. Bu nedenle tezdeki ToM kullanımı iddialı ama sınırlıdır: çalışma, insan ToM'unun tam karşılığını değil, kullanıcı profillemeye bağlamında ToM-benzeri işlevsel bir mimariyi tartışır.

LLM bağlamında ToM tartışması özellikle Kosinski'nin çalışmasıyla popülerleşmiştir. Kosinski, çeşitli false-belief ve zihinsel durum çıkarımı görevlerinde GPT ailesi modellerinin performansını incelemiş ve yeni nesil LLM'lerde ToM-benzeri davranışların kendiliğinden ortaya çıkmış olabileceğini öne sürmüştür [8]. Bu iddia önemlidir fakat temkinli okunmalıdır: Bir LLM'in ToM testlerinde iyi performans göstermesi, onun insan gibi zihinsel durumlara sahip olduğu anlamına gelmez; dilsel örüntüleri ve görev formatlarını iyi öğrenmiş olması da mümkündür.

Bu tez Kosinski'nin açtığı tartışmada daha dar ama daha operasyonel bir iddia kurar. Kosinski çizgisindeki soru çoğunlukla “LLM bir ToM görevini çözebilir mi?” biçimindedir; TarotFlow'un sorusu ise “LLM bir kullanıcı hakkında zaman içinde güncellenen, yanlışlanabilen ve davranışsal çıktıyı değiştiren bir zihinsel-durum modeli kurabilir mi?” biçimindedir. Bu fark kritiktir: tek bir test sorusu doğru cevaplanabilir, fakat kullanıcı modeli ancak çoklu etkileşim, hafıza, geri bildirim, çelişki ve kişiselleştirilmiş sonraki çıktı üzerinden sınanabilir. Dolayısıyla bu tez, LLM'lerin theory of mind'ı tam anlamıyla gerçekleştirdiğini değil, ToM literatüründen türetilmiş işlevsel ölçütlerin ürün mimarisi içinde nasıl yaklaştırılabileceğini savunur.

2.2 Computational Theory of Mind: Hesaplanabilir Kullanıcı Modeli

Bu tezde “computational” kelimesi, yalnızca bilgisayarda çalışan bir sistem anlamına gelmez. Computational vurgu, zihinsel durumların formel olarak temsil edilmesi, gözlenen davranışlardan çıkarım yapılması ve bu temsilin yeni verilerle güncellenmesi anlamına gelir. Tenenbaum, Saxe, Baker ve çalışma arkadaşlarının Bayesian Theory of Mind çizgisi bu açıdan temel referanstır: İnsanların başkalarının eylemlerini, altta yatan inanç ve arzulara dair olasılıksal çıkarımlar yaparak yorumladığını modellemeye çalışır [7]. Bu yaklaşımda zihin okuma doğaüstü bir sezgi değil, gözlenen davranıştan görünmeyen amaç ve inançlara yapılan tersine çıkarımdır.

Rabinowitz ve arkadaşlarının DeepMind'da geliştirdiği “Machine Theory of Mind” çalışması da bu fikri makine öğrenmesi bağlamına taşır. ToMnet adlı model, farklı ajanların davranışlarını gözlemleyerek onların karakteristiklerini, hedeflerini ve gelecekteki davranışlarını tahmin etmeyi öğrenir; hatta bazı false-belief benzeri durumlarda ajanların hatalı inançlarına duyarlı tahminler üretir [22]. TarotFlow'un mimari iddiası bu çizgiyle akrabadır fakat daha mütevazıdır: sistem kullanıcının zihnine erişmez; yalnızca dilsel ve davranışsal izlerden çıkarılmış, kaynakları tutulmuş ve yanlışlanabilir hipotezler üretir.

Bu modelin insan Theory of Mind'ından farkı açıktır. LLM bilinçli değildir; kullanıcının zihnine doğrudan erişmez; empati deneyimlemez. Ayrıca bu çalışmada sistem, kullanıcının kendisinin bilmediği bir gerçeği keşfettiğini veya klasik yanlış-inanç görevlerini çözdüğünü iddia etmez. Gösterilmek istenen daha sınırlıdır: kullanıcıdan gelen tekrar eden sinyaller, itirazlar, onaylar ve davranışsal karşı-kanıtlar saklanıp güncellendiğinde, sonraki üretim daha kişiye özgü ve daha test edilebilir hâle gelebilir. Bu nedenle tez boyunca “computational theory of mind” ifadesi, tam gerçekleşmiş bir zihin kuramı değil, dinamik kullanıcı modeli için yön gösterici bir çerçeve olarak kullanılacaktır.

2.3 Şema Terapisi: Klinik Hipotez Dili

Şema Terapisi, özellikle Young, Klosko ve Weishaar'ın çalışmasıyla sistemleşen ve erken dönem uyumsuz şemaları kişinin tekrar eden duygu, ilişki ve başa çıkma örüntülerini anlamak için kullanan klinik bir yaklaşımdır [17]. Literatürde sıklıkla “18 Early Maladaptive Schemas” olarak anılan bu çerçeve, kişinin terk edilme, kusurluluk, duygusal yoksunluk veya yüksek standartlar gibi tekrar eden temalarını sınıflandırmaya çalışır. TarotFlow'un erken sürümleri bu şema dilinden fazla etkilenmiş ve bazı kullanıcı davranışlarını hazır şema kutularına zorla yerleştirme eğilimi göstermiştir. Bu tezde şema dili bu nedenle tanı koymak için değil, sistemin ürettiği hipotezleri adlandırmak ve daha sonra falsifikasyona açmak için sınırlı bir klinik sözlük olarak kullanılır.

2.4 Ironic Process Theory: Yasaklama ve İç Ses Problemi

Wegner'ın Ironic Process Theory çalışması, bir düşünceyi bastırmaya veya düşünmemeye çalışmanın o düşünceyi zihinde daha erişilebilir hâle getirebileceğini gösterir [15]. Bu mekanizma TarotFlow'un prompt tasarımında doğrudan gözlenmiştir: modele yalnızca “klinik terim kullanma” dendiğinde model Jungian, schema veya archetype gibi terimlere daha fazla odaklanmış; yasak listesi, istenmeyen dili tamamen söndürmek yerine onu prompt içinde daha görünür hâle getirmiştir. Bu nedenle nihai mimari yasaklamayı tek başına çözüm olarak kullanmaz; modelin psikolojik analiz ihtiyacını `internal_monologue` alanında izole eder ve kullanıcıya yalnızca `final_output` içindeki sembolik tarot dilini gösterir.

2.5 Projektif Testler, Tarot ve Psikolojik Yansıtma

Projektif teknikler, belirsiz uyarıcılara verilen yanıtların kişinin iç dünyasına dair ipuçları taşıyabileceği varsayımına dayanır [11, 5]. Rorschach testi, kişiye mürekkep lekesi gibi belirsiz görseller gösterip “burada ne görüyorsun?” sorusuyla yorum alır; TAT ise kişiye belirsiz sosyal sahneler gösterip hikâye kurmasını ister. Bu testlerde amaç, uyarının kendisinden çok kişinin o belirsiz uyarıyı nasıl anlamlandırdığına bakmaktır. Ancak projektif testlerin psikometrik statüsü tartışmalıdır. Lilienfeld, Wood ve Garb, bazı sınırlı indeksler için destek bulunsa da birçok projektif yorumun bilimsel geçerlik açısından zayıf olduğunu belirtir [13]. Bu eleştiri TarotFlow için sınır çizicidir: Tez tarotun klinik tanı aracı olduğunu savunmaz; tarotun kullanıcıdan doğal, savunması düşük ve psikolojik açıdan zengin veri almak için projektif bir arayüz olarak kullanılabileceğini savunur.

Bu nedenle tarot, bu tezde metaforik olarak tarihin en ilkel Rorschach yüzeylerinden biri gibi ele alınır. Tarot kartı tek başına bilimsel ölçüm yapmaz; fakat kişi belirsiz ve sembolik bir karta kendi sorusunu, korkusunu, beklentisini ve itirazını yansıtır. Örneğin aynı “Ölüm” kartı bir kullanıcı için mezuniyeti engelleyen erteleyen öğrenci kimliğinin bitmesi, başka bir kullanıcı için eski ilişkinin eski formunun kapanması anlamına gelebilir. Bilimsel açıdan önemli nokta kartın kehanet gücü değil, belirsiz sembolün kullanıcıdan kişiye özgü reaksiyon, bağlam ve çoğu zaman doğrudan sorulsa savunmayla karşılaşabilecek psikolojik malzeme üretmesidir.

Bu mekanizma gündelik dille “bilinçaltımı bilinçüstüne çıkarma” gibi anlatılabilir; daha temkinli bir akademik ifadeyle tarot, örtük veya yarı bilinçli çağrışımları açık söze dönüştüren bir reflection yüzeyi sağlar. Rorschach'ta mürekkep lekesine “burada ne görüyorsun?” diye sorulması gibi, tarot da sembolik bir imge üzerinden “bu kart sende neyi çağırıyor?” sorusunu üretir. Örneğin Asılan Adam kartı kullanıcıya “you have to let it go” ya da “bir şeyi bırakman gerekiyor” şeklinde sunulduğunda, kullanıcının aklına ilk gelen konu çoğu zaman karttan bağımsız olarak

psikolojik açıdan anlamlıdır: eski ilişki, yarım kalmış bir iş, kontrol etme ihtiyacı, aile beklentisi veya başarısızlık korkusu. Kart burada kehanet üretmez; kişinin zaten taşıdığı fakat doğrudan sorulduğunda savunmayla saklanabilecek meseleyi dışsallaştırır ve kullanıcının kendi üzerine reflection yapmasını kolaylaştırır.

Tarot literatüründe psikolojik açıklamalar genellikle Barnum etkisi ve cold reading ile tartışılır. Barnum/Forer etkisi, bireylerin genel kişilik ifadelerini kendilerine özelmış gibi kabul etme eğilimidir [10, 6]. Cold reading ise okuyucunun geri bildirim ve yüksek olasılıklı tahminlerle özelleştirilmiş bilgi izlenimi yaratmasıdır [9]. TarotFlow’un amacı bu mekanizmaları inkâr etmek değil, mimari olarak aşmaya çalışmaktır: Gate, consolidation, RAG ve profil kartı katmanları olmadan bir LLM tarot uygulaması kolayca Barnum makinesine dönüşebilir.

Barnum etkisi de basit bir örnekle görünür hâle gelir. “Dışarıdan güçlü görünüyorsun ama içten içe anlaşılmadığını hissediyorsun”, “bazen insanlara çok yakın olmak istiyorsun, bazen de geri çekiliyorsun” veya “potansiyelinin tamamını kullanamadığını düşünüyorsun” gibi cümleler birçok insana uyabilecek kadar geneldir; yine de kişi bunları kendi hayatındaki somut olaylarla doldurarak çok kişisel algılayabilir. Ham LLM çıktılarının tehlikesi de buradadır: model bu tür yüksek kapsayıcılığa sahip cümleleri çok etkileyici bir dille üretebilir. TarotFlow’un iddiası, bu genel cümleleri daha süslü söylemek değil; kullanıcının önceki mesajları, itirazları, onayları, tekrar eden temaları ve RAG ile geri çağrılan bağlamları sayesinde hangi cümlelerin gerçekten o kullanıcıya ait olduğunu test etmeye çalışmaktır.

2.6 LLM Hafızası, Generative Agents ve Reflection Architecture

Park ve arkadaşlarının “Generative Agents” çalışması, LLM tabanlı ajanlarda memory stream, reflection ve planning bileşenlerinin inandırıcı davranışlar üretebildiğini göstermiştir [23]. TarotFlow bu üçlüyü psikolojik profillemeye bağlamına uyarlar: `clinical_observations` ve `user_memory` memory stream; consolidation reflection; Smart Action Planner ise planning işlevini üstlenir.

OpenAI’nin Dreaming V3 duyurusu, bu mimari paralelliği güncel ürün ölçeğinde güçlendiren bir dış örnektir. OpenAI, hafızanın staleness, correctness ve scalability sorunlarını çözmek için arka plan sentezine dayalı bir sistem geliştirdiğini; memory’nin kullanıcı tercihleri, projeleri ve kısıtlarını öğrenerek gelecek konuşmaların sıfırdan başlamamasını sağladığını belirtmiştir [19]. TarotFlow da benzer şekilde kullanıcıyı her tarot seansında sıfırdan ele almak yerine, eski sinyalleri konsolide ederek yeni okumalara kontrollü biçimde taşır.

2.7 RAG ve Kişiselleştirilmiş Üretim

Retrieval-Augmented Generation, modelin yalnızca parametric memory’sine güvenmek yerine dış veri kaynaklarından bağlam çekerek üretim yapmasını sağlar [12]. TarotFlow’da RAG ansiklopedik bilgi için değil, kullanıcının geçmiş psikolojik gözlemlerini yeni kart yorumuna bağlamak için kullanılır. Ancak naive RAG, geçmiş notları yanlış bağlamda prompt’a sokarak confirmation bias üretebilir. Bu nedenle sistemde Card-Driven RAG tasarlanmıştır: Önce kartların bağımsız teması çıkarılır, sonra geçmiş gözlemler bu tema üzerinden aranır.

3 Metodoloji ve Sistem Mimarisi

Bu bölüm iki katmanlıdır. İlk olarak çalışmanın araştırma metodolojisi, veri toplama biçimi ve değerlendirme yaklaşımı açıklanır. Ardından bu metodolojik tercihi mümkün kılan ürün mimarisi; Gate, hafıza, reflection, RAG ve vektör tabanlı retrieval bileşenleri üzerinden teknik olarak detaylandırılır.

3.1 Araştırma Metodolojisi

Bu çalışma, karma yöntem yaklaşımı benimseyen keşifsel bir pilot araştırma olarak tasarlanmıştır. Karma yöntem tasarımları, nicel ölçümler ile nitel vaka yorumlarını aynı araştırma sorusu etrafında birleştirmeyi amaçlar; TarotFlow’da nicel taraf gate sayıları, signal type dağılımları, RAG hit oranları, kör profil ayırt etme sonuçları ve function log metrikleriyle, nitel taraf ise profil kartları, kart yorumları ve uzman değerlendirmesiyle temsil edilir [4]. Çalışma formal bir klinik deney, psikometrik validasyon veya terapötik etkililik testi değildir. Amaç, LLM’lerin doğal dil işleme kapasitesinin dinamik hafıza, reflection ve retrieval mimarisiyle birleştğinde kullanıcıya özgü psikolojik hipotezler üretip üretmediğini doğal kullanım içinde gözlemlemektir.

Geleneksel anket veya yapılandırılmış mülakat yerine tarot metaforunun kullanılmasının nedeni, kullanıcıdan doğrudan “psikolojini anlat” talep etmeden psikolojik açıdan zengin ve savunması daha düşük veri üretmesidir. Bu tercih, Bölüm 2’de tartışılan projektif teknik mantığıyla ilişkilidir: belirsiz ve sembolik bir uyaran, kullanıcının kendi korku, beklenti, itiraz ve çağrışımlarını dışsallaştırmasına aracılık eder [11, 5]. Bu nedenle tarot burada klinik tanı aracı değil, LLM’in kişiye özgü bağlam kurma kapasitesini gözlemlemek için kullanılan projektif bir araştırma arayüzüdür.

Final analiz seti, TarotFlow mobil uygulamasını doğal ortamında kullanan 12 bağımsız pilot kullanıcı ile aynı gerçek kişiye ait bir legacy regresyon hesabından oluşur. Legacy hesap yalnızca eski/yeni mimari karşılaştırması için tutulmuş, bağımsız katılımcı sayısına dahil edilmemiştir. Kullanıcılara uygulamanın yapay zekâ tarafından yönetildiği ve anonimleştirilmiş ürün kayıtlarının araştırma/prototip geliştirme amacıyla incelenebileceği belirtilmiş; ancak arka planda Psychological Gate, consolidation ve profil kartı üretimi gibi psikolojik profillemeye bileşenleri kullanıcı deneyiminin ön yüzüne taşınmamıştır. Bu tercih, gözleniyor olmanın katılımcı davranışını değiştirebilmesi anlamına gelen Hawthorne etkisini azaltmaya yöneliktir [14]. Veri toplama sürecinde 38 tarot seansı, 312 mesaj ve sistemin arka planda ürettiği yürütme kayıtları PostgreSQL veritabanında tutulmuştur.

Mühendislik yöntemi de tek seferlik tasarım değil, hata analizine dayalı iteratif bir geliştirme sürecidir. Sistem V1’den V8’e kadar çevik ve deneysel bir döngüyle olgunlaştırılmıştır: her Barnum etkisine açık yanıt, RAG kirliliği, kaynak kirlenmesi veya “preachy therapist” etkisi bir failure case olarak ele alınmış; ardından mimari değişiklik yapılmış ve sistem yeniden kullanım logları üzerinden değerlendirilmiştir. Bu yaklaşım, çevik yazılım geliştirmedeki kısa geri bildirim döngülerinin araştırma prototipine uyarlanmasıdır [3]. Bu nedenle Bölüm 4’teki deneyler yalnızca hata listesi değil, mimarinin neden bugünkü hâline geldiğini gösteren metodolojik kanıtlardır.

Değerlendirme dört ana yöntemle yapılmıştır. Birincisi forensic log analizidir: planner kararları, gate confidence değerleri, RAG hit/miss durumları, `internal_monologue` ve `final_output` ayrımı geriye dönük olarak incelenmiştir. İkincisi çapraz vaka karşılaştırmasıdır: User A, User B ve User C gibi farklı kullanıcıların profil çekirdekleri, gate sinyalleri ve aynı kartlara verilen bağlama özgü yorumlar nitel olarak karşılaştırılmıştır [18]. Üçüncüsü Barnum kontrolüdür:

katılımcılara kendi profili, başka kullanıcının profili ve kendi baskın yüzey temasına benzetilmiş Barnum profili kör biçimde gösterilmiş; profillerin en çok benzeyenden en az benzeyene doğru sıralanması istenmiştir. Dördüncüsü klinik akla yatkınlık değerlendirmesidir: sistem çıktıları kesin klinik teşhis veya tedavi önerisi olarak değil, eldeki dilsel kanıta dayalı hipotezler olarak ele alınmış ve bir Uzman Klinik Psikolog tarafından yüz geçerliği, aşırı iddia riski ve etik çerçeveleme açısından incelenmiştir.

Anonimleştirme açısından isimlendirme şu şekilde tutulmuştur: User A, User B ve User C metinde ayrıntılı anlatılan üç vaka çekirdeğini ifade eder. P01–P12 kodları kör profil testindeki bağımsız pilot kullanıcıları temsil eder. Legacy User A ise User A ile aynı gerçek kişinin eski sistemdeki ayrı hesap kayıdır ve yalnızca eski/yeni regresyon karşılaştırmasında kullanılır. Dolayısıyla User B ve User C, User A’dan farklı kullanıcılardır; aynı kişi karşılaştırması yalnızca Legacy User A ile User A (yeni) arasındadır.

Uygulamanın kullanıcıya görünen dili Türkçedir; buna karşılık sistem promptlarının ve JSON alan adlarının önemli bölümü İngilizce yazılmıştır. Bu nedenle ham `internal_monologue` logları çoğu zaman İngilizce, kullanıcı mesajları ve `final_output` ise Türkçedir. Tezde İngilizce iç ses alıntıları çevrilmeden verilmiştir; bunun nedeni çeviriyle analitik tonun veya klinik terim sızıntısının kaybolmasını önlemektir. Yorumlanan kullanıcı mesajları ise kimlikleyici ayrıntılar temizlenerek Türkçe aktarılmıştır.

Son olarak, değerlendirme yalnızca kullanıcıya görünen final yanıtlarla sınırlı tutulmamıştır. Function log kayıtları üzerinden yorumun hangi sinyal, hangi retrieval sonucu ve hangi mimari karar üzerinden üretildiği denetlenmiştir. Bu sayede sistemin “iyi yorum yapması” tek başına yeterli görülmemiş; yorumun kaynak izlenebilirliği, karşı-kanıtla güncellenebilirliği ve Barnum kontrolündeki ayırt edilebilirliği birlikte değerlendirilmiştir.

3.2 Kör Barnum Değerlendirme Protokolü

Barnum etkisine karşı değerlendirme iki aşamalı körleme protokolüyle yürütülmüştür. Birinci aşama uzman körleme testidir. User A, User B, User C ve kasıtlı olarak User A’nın ilişki/mesafe yüzey temasına benzetilmiş bir Barnum kontrol profili aynı formatta, benzer uzunlukta, benzer psikanalitik soyutluk düzeyinde ve köken bilgisi kaldırılmış biçimde dört profil kartına dönüştürülmüştür. Profiller randomize edilerek Uzman Klinik Psikolog İrem Tatar’a yalnızca “Profil 1–4” etiketleriyle gösterilmiştir. Değerlendiriciye hangi profilin sistem çıktısı, hangisinin Barnum kontrolü olduğu söylenmemiştir. Test materyallerinin tam metni Appendix A’da, değerlendirme formu Appendix C’de ve uzman yanıtları Appendix D’de verilmiştir.


Kontrol profilleri bilinçli olarak Barnum/Forer etkisini maksimize edecek şekilde yazılmıştır: geniş popülasyonlara uyabilecek çift yönlü ifadeler, yakınlık/mesafe ikilemi, anlaşılma arzusu, potansiyelini tam kullanamama hissi, yüksek standartlar ve savunmacı geri çekilme gibi çok kapsayıcı temalar kullanılmıştır. Buna ek olarak kullanıcı testindeki Barnum kontrolleri herkese verilen tek bir metin değildir; her kullanıcı için TarotFlow profilinin ana temasına benzer, aynı uzunlukta ve aynı bilimsel/psikanalitik tonda tematik eşlenmiş Barnum profili yazılmıştır. Böylece test kolaylaştırılmamış, aksine zorlaştırılmıştır: profil metinleri somut ipuçlarından arındırılmış, fakat Barnum metni kullanıcının genel temasına özellikle yaklaştırılmıştır. Bu nedenle testin kontrol cümlesi şudur: *Thematically matched Barnum profiles were constructed to maximize the Forer effect by using broad-population statements while mirroring each target profile’s surface theme* [10].

İkinci aşama kullanıcı profil tanıma testidir. Her katılımcıya üç profil gösterilmiştir: kendi TarotF-

low profil kartı, başka bir kullanıcının profil kartı ve aynı kullanıcının geniş temasına benzetilerek yazılmış tematik eşlenmiş Barnum profili. Profillerin kaynağı açıklanmamış; kullanıcıdan yalnızca şu sıralama istenmiştir: “Bu üç profilden hangisi sizi en iyi tanımlıyor? Lütfen en çok benzeyen profilden en az benzeyen profile doğru sıralayın.” Katılımcılara açıklama, yönlendirme, somut olay hatırlatma veya “sistem profili hangisi olabilir?” gibi ipucu verilmemiştir. Bu test, profil kartının hem başka kullanıcı profiline hem de aynı kullanıcının temasını taklit eden zorlayıcı Barnum kontrolüne karşı ayırt edilebilir olup olmadığını ölçer.

3.3 Sistem Mimarisi Genel Akışı

TarotFlow’un mimarisi, LLM’in kullanıcıya dair ToM-benzeri işlevsel bir model kurmaya yaklaşması için gereken beş ürüne dönük işlevi karşılar: sinyal seçimi, hafıza, reflection, retrieval ve güvenli üretim. Temel akış Şekil 1’de gösterilmiştir.



Şekil 1: TarotFlow: ToM-benzeri kullanıcı modeli için reflection tabanlı ürün mimarisi

Bu akışın bilgisayar mühendisliği açısından önemi, LLM çağrılarının tek bir uzun prompt içinde erimemesi, her kararın ayrı bir veri nesnesi ve ayrı bir denetlenebilir ara çıktı olarak tutulmasıdır. Sistem bu nedenle klasik “chatbot” akışından çok, olay güdümlü bir kullanıcı-modelleme pipeline’ı gibi tasarlanmıştır: planner kullanıcı niyetini sınıflandırır, gate sinyal adayını üretir, consolidation hipotez durumunu günceller, RAG yalnızca eşik üstü bağlamı çağırır ve iki aşamalı üretim katmanı analitik içeriği kullanıcıya görünen dilden ayırır.

Veri modeli bu ayrımı korumak için özellikle parçalı tutulmuştur. Aynı metnin hem kronolojik hafıza, hem klinik hipotez, hem retrieval girdisi, hem de kullanıcıya görünen cevap gibi davranmasına izin verilmemiştir. Böylece sistemdeki her kayıt için “bu bilgi nereden geldi, hangi modül üretti, sonraki çıktıyı nasıl etkiledi?” sorusu loglardan izlenebilir hâle gelir.

Tablo 2: TarotFlow veri kontratı ve denetlenebilir ara çıktılar

Kayıt ailesi	Tutulan alanlar	Mühendislik işlevi
Gate gözlemleri	<code>clinical_observations</code> : <code>signal_type</code> , confidence, source, hypothesis status, kısa kanıt metni	Ham kullanıcı mesajını profil adayına dönüştürür; NEW , CONFIRMED veya CHALLENGED ayrımıyla falsifikasyonu mümkün kılar.
Kronolojik hafıza	<code>user_memory</code> : seans özeti, açık kullanıcı bilgisi, zaman bağlamı	RAG için uzun dönem bağlam sağlar; ancak tek başına klinik hipotez sayılmaz.
Yürütme logları	<code>function_logs</code> : planner kararı, kartlar, RAG sonucu, similarity skoru, <code>internal_monologue</code> , <code>final_output</code>	Her okumanın yürütme izini saklar; hata analizi ve regression kontrolü yapılmasını sağlar.
Profil kartı	Core belief, savunma örüntüsü, destekleyen/çürüten sinyaller, confidence	Dağınık gözlemleri kompakt kullanıcı modeline çevirir; sonraki yorumlara kontrollü kişiselleştirme verir.

Bu tablo tezin mühendislik omurgasını özetler: kişiselleştirme yalnızca LLM’in “iyi tahmin” yapmasına bırakılmamış, typed kayıtlar, confidence değerleri, threshold kararları ve kalıcı yürütme loglarıyla denetlenebilir bir sistem davranışına dönüştürülmüştür.

Çalışma zamanı algoritması sadeleştirilmiş biçimde şöyledir:

1. Kullanıcı mesajı geldiğinde Smart Action Planner mesajı **READING**, **CHAT** veya **FEEDBACK** olarak sınıflandırır.
2. Mesaj gate katmanından geçer; yalnızca kaynak ayrımı ve baseline filtrelerini aşan ifadeler `clinical_observations` kaydına dönüşür.
3. Yeterli sinyal biriktiğinde consolidation eski hipotezleri yeni kanıtla karşılaştırır ve her hipotezi **NEW**, **CONFIRMED** veya **CHALLENGED** olarak günceller.
4. Yeni tarot okumasında kartlardan bağımsız bir semantik sorgu üretilir; `pgvector` üzerinde cosine similarity araması yapılır.
5. Eşik üstü bağlam yoksa sistem **NO_RELEVANT_OBSERVATIONS** durumunu kabul eder; eşik üstü bağlam varsa bu bağlam düşük öncelikli arka plan olarak prompt’a eklenir.
6. Model önce `internal_monologue` içinde kart, profil ve retrieval bağlamını tartar; sonra `final_output` alanında yalnızca kullanıcıya uygun sembolik dili üretir.
7. Planner kararı, retrieval sonucu, similarity skoru ve iki aşamalı çıktı `function_logs` kaydına yazılır; böylece aynı okuma daha sonra hata analizi için yeniden incelenebilir.

3.4 Psychological Gate: Ham Mesajdan Sinyal Seçimi

Sistemin ilk görevi her şeyi analiz etmek değildir; neyin analiz edilmeye değer olduğunu seçmektir. Bu nedenle Psychological Gate, kullanıcının mesajında psikolojik materyal olup olmadığını değerlendirir. V7 ile her gate çıktısı bir `signal_type` alır: `self_disclosure`, `behavioral_sequence`, `feedback_response` veya `communication_style`. Bu taksonomi, tarot uygulamasında normal olan davranışları patolojize etmemek için eklenmiştir.

Baseline awareness burada sonradan yamalanmış bir hata değil, ürünün temel güvenlik özelliğidir. Tarot bağlamında geleceği sormak, net cevap istemek veya karşı tarafın ne düşündüğünü merak etmek olağan kullanıcı davranışıdır; sistem bunları tek başına psikolojik semptom gibi kaydetmez. Gate yalnızca kullanıcının kendi iç durumunu açtığı, davranış dizisi gösterdiği veya önceki hipotezi açıkça destekleyen/çürüten mesajları profile aday sinyal olarak geçirir.

Buna ek olarak Gate için kaynak ayrımı kuralı uygulanır: profil kanıtı yalnızca kullanıcının kendi kelimelerinden veya kullanıcının açık geri bildiriminden üretilebilir. Botun tarot yorumu, planner gerekçesi veya gizli analizi bağlam sağlayabilir; fakat kullanıcı tarafından doğrulanmadıkça clinical observation için birincil kaynak sayılamaz.

3.5 Reflection ve Falsifikasyon

Reflection pipeline iki ayrı işi birbirine karıştırmadan yürütür. Birinci katman `session-reflection` akışıdır: seans bittiğinde konuşmanın kısa bir oturum özeti çıkarılır ve konuşma kronolojisinin sonraki seanslarda kaybolmaması sağlanır. Bu katman tek başına yeni profil şeması üretmez; görevi seansı dosyalamak ve sonraki analiz için ham bağlamı düzenlemektir.

İkinci katman signal-based consolidation'dır. Consolidation modülü, ham gözlemleri doğrudan profil kartına yazmaz. En az 5 anlamlı sinyal biriktiğinde çalışır ve yeni sinyalleri eski hipotezlerle karşılaştırır. Çıktı üç kategoriye ayrılır: **CONFIRMED**, **CHALLENGED** ve **NEW**. Bu yapı önemlidir; çünkü kullanıcı hakkında işlevsel bir model kurduğunu iddia eden bir sistem yalnızca hipotez üretmemeli, aynı zamanda hipotezlerini çürütebilmelidir. Falsifikasyon olmadan profil kartı yalnızca kendini doğrulayan Barnum anlatısına dönüşür.

Consolidation için en kritik güvenlik kuralı kaynak izlenebilirliğidir. Bir hipotez ancak kullanıcı mesajından, kullanıcının açık onay/itirazından veya daha önce kullanıcı kaynaklı olarak kaydedilmiş gözlemden beslenebilir. Asistanın kendi yorumu, örneğin “sen ideal aşk arıyorsun” gibi bir okuma, kullanıcı doğrulamadıkça yeni şema kanıtı olamaz.

Bu ayrım önceki tasarım hatasından doğmuştur: seans özeti, profil güncelleme ve klinik formülasyon aynı prompt içinde karıştığında sistem hem fazla erken teşhis üretir hem de kendi önceki anlatısını doğrulanmış veri gibi saklama riski taşır. Nihai mimaride oturum özeti kronolojik hafıza için, consolidation ise yalnızca yeterli sinyal biriktiğinde profil güncellemek için kullanılır.

3.6 İç Ses İzolasyonu

Modelin psikolojik analizleri doğrudan kullanıcıya söylemesi “preachy therapist” etkisi yaratmıştır. Bu nedenle üretim iki aşamaya ayrılmıştır: `internal_monologue` alanında psikolojik profil, kart anlamları ve RAG bağlamı tartışılır; `final_output` alanında ise kullanıcı yalnızca mistik ve

sembolik tarot dilini görür. Böylece LLM’in psikanalitik pattern recognition kapasitesi korunurken, kullanıcı deneyimi terapi seansına veya didaktik teşhise dönüşmez.

3.7 Vector Embeddings ve Cosine Similarity (Matematiksel Altyapı)

TarotFlow’un Card-Driven RAG katmanı, geçmiş gözlemleri yalnızca düz metin olarak saklayan bir arama sistemi değildir. Her gözlem, embedding modeli tarafından yüksek boyutlu bir vektör uzayında temsil edilir. Biçimsel olarak bir embedding fonksiyonu

$$E : \text{text} \rightarrow \mathbb{R}^d$$

şeklinde düşünülebilir. Bir geçmiş gözlem o_i için saklanan temsil $v_i = E(o_i)$ vektörüdür. Yeni bir tarot okumasında sistem önce kullanıcı sorusunu doğrudan aramak yerine kartların bağımsız semantik temasını çıkarır; bu tema q olarak adlandırılır ve aynı embedding uzayına $u = E(q)$ biçiminde gömülür. Böylece retrieval problemi, “hangi metin aynı kelimeleri içeriyor?” sorusundan “hangi geçmiş gözlem bu kart temasına anlamsal olarak en yakın?” sorusuna çevrilir.

İki embedding arasındaki anlamsal yakınlık cosine similarity ile hesaplanır. A ve B iki vektör olmak üzere:

$$\text{CosineSimilarity}(A, B) = \frac{A \cdot B}{\|A\| \|B\|}$$

Burada $A \cdot B$ iki vektörün noktasal çarpımı, $\|A\|$ ve $\|B\|$ ise vektör normlarıdır. Skorun yüksek olması, iki metnin aynı kelimeleri kullanmasından çok, embedding uzayında benzer yönlelere sahip olmasına dayanır. TarotFlow açısından bu önemlidir: “okul baskısı”, “mezuniyet korkusu” ve “sorumluluk yükü” gibi farklı yüzey biçimleri, aynı psikolojik temaya yakın vektörler olarak temsil edilebilir.

Card-Driven RAG’ın matematiksel akışı şu şekilde özetlenebilir. Geçmiş gözlemler $O = \{o_1, o_2, \dots, o_n\}$ kümesi olarak tutulur. Her gözlem için $v_i = E(o_i)$ hesaplanır ve veritabanına kaydedilir. Yeni okuma sırasında kart teması q için $u = E(q)$ üretilir. Daha sonra her gözlem için

$$s_i = \text{CosineSimilarity}(u, v_i)$$

skoru hesaplanır ve sistem yalnızca en yüksek skorlu, eşik değerini geçen gözlemleri prompt’a taşır. Bu nedenle RAG çıktısı LLM’in sezgisel olarak “hatırlaması” değil, vektör uzayında yapılan sayısal bir en yakın komşu aramasıdır.

Bu aramada thresholding mekanizması kritik bir güvenlik filtresi olarak çalışır. Eğer τ cosine similarity eşiği ise, retrieval kararı şu kurala bağlanır:

$$\max_i s_i < \tau \Rightarrow \text{NO RELEVANT OBSERVATIONS}$$

Uygulama düzeyinde $\tau = 0.70$ eşiği kullanılmıştır. Bu değer keyfi bir sayı olarak değil, küçük bir geliştirme kalibrasyonundan sonra seçilmiştir. 30 anonim query–observation çifti elle “ilgili/ilgisiz”

olarak incelenmiş; düşük eşiklerin alakasız eski notları prompt’a taşıdığı, yüksek eşiklerin ise gerçekten yararlı kişisel bağlamı kaçırdığı görülmüştür.

Tablo 3: Cosine similarity eşiği için pilot kalibrasyon özeti

Eşik	Gözlenen davranış	Yorum
0.60	Çok sayıda hit; yaklaşık üçte biri zayıf veya alakasız	Recall yüksek, fakat confirmation bias ve Barnum riski fazla.
0.70	Daha az ama çoğunlukla anlamlı hit; alakasız çağırma belirgin azaldı	Bu tezde kullanılan güvenli denge noktası.
0.80	Çok seçici; birçok makul geçmiş bağlam dışarıda kaldı	Precision yüksek, fakat kişiselleştirme zayıflıyor.

Bu kalibrasyon istatistiksel olarak genellenebilir bir optimum iddiası taşımaz; yalnızca bu veri setinde ve kullanılan embedding modeliyle seçilmiş mühendislik eşiğidir. Gelecek sürümde τ sabit bir sayı olmak yerine kullanıcı başına veri yoğunluğu, gözlem tipi ve kart teması güvenine göre dinamik ayarlanabilir. Yine de mevcut eşik, sistemin her kart okumasında geçmişten mutlaka bir şey bulmaya çalışmasını engeller; vektör uzayında yeterli benzerlik yoksa sistem “bilmiyorum” demeyi tercih eder.

Bu noktada yalnızca eşik değeri değil, embedding’e verilen metnin soyutluk düzeyi de belirleyicidir. Geliştirme sırasında görülen önemli bir failure mode şudur: tarot kartlarından türetilen sorgular çoğu zaman “yük”, “belirsizlik”, “dönüşüm”, “irade” gibi üst düzey temalar üretirken, bazı clinical observation kayıtları “kullanıcı yeni iş başvurusu yaptığını söyledi” veya “okul takvimi hakkında konuştu” gibi çok somut kalmıştır. İnsan okuyucu bu kayıtların aynı stres ve sorumluluk temasına bağlanabileceğini görebilir; ancak embedding uzayında sorgu tematik, doküman ise olay düzeyinde temsil edildiğinde cosine similarity düşük kalabilmiştir. Bu nedenle V8’de retrieval girdileri iki parçalı tutulmuştur: olay cümlesi korunmuş, fakat yanında kısa bir tema özeti ve kaynak tipi metadata’sı eklenmiştir. Böylece sistem hem somut provenance’ı kaybetmemiş hem de RAG sorgusunu kart temasıyla aynı semantik çözünürlükte arayabilir hâle gelmiştir.

Bu vektör hesaplamaları uygulama belleğinde manuel olarak yapılmaz. TarotFlow’da embedding kayıtları PostgreSQL veritabanında `pgvector` eklentisiyle saklanır ve cosine similarity tabanlı sıralama veritabanı katmanında yürütülür. Bu tercih iki mühendislik avantajı sağlar. Birincisi, hafıza büyüdükçe uygulama sunucusunun tüm geçmiş gözlemleri belleğe almasına gerek kalmaz. İkincisi, retrieval denetlenebilir hâle gelir: sorgu vektörü, dönen gözlemler, similarity skoru ve threshold kararı `function_logs` üzerinden izlenebilir. Dolayısıyla sistemin kişiselleştirme iddiası yalnızca prompt mühendisliğine değil, veritabanında çalışan ölçülebilir vektör aramasına dayanır.

4 Deneyler ve İteratif Geliştirme

Geliştirme süreci doğrusal bir tasarım başarısı değil, ardışık hatalar üzerinden olgunlaşan bir mimari evrimdir. Bu bölüm her iterasyonu aynı formatla sunar: **sorun**, **kök neden**, **çözüm** ve **öğrenilen ders**. Amaç yalnızca son sistemin nasıl çalıştığını göstermek değil, hangi tasarım

kararlarının neden zorunlu hâle geldiğini belgelemektir.

4.1 V1–V8 Mimari Evrim Özeti

Tablo 4: TarotFlow V1–V8 mimari evrimi

Versiyon	Dönem	Ana yenilik	Ortaya çıkan ana sorun
V1	İlk tasarım	Tüm geçmiş konuşmayı prompt’a ekleyen tam context-window yaklaşımı	Ölçeklenmedi; token maliyeti ve bağlam taşması oluştu.
V2	İlk hafıza	<code>user_insights</code> tablosu ve naive semantic RAG	Alakasız eski şemalar yeni okumalara karıştı; RAG kirliliği oluştu.
V3	Gate eklendi	Psychological Gate ile mesajdan psikolojik sinyal seçimi	Mesaj uzunluğu ve stilistik ipuçları fazla ağırlık aldı; sinyal kalitesi düştü.
V4	Consolidation	5 anlamlı sinyalde çalışan signal-based consolidation	Eski seans-sonu consolidation ile yeni sistem çakıştı; asistan yorumu kullanıcı kanıtına karışabildi.
V5	İç ses	<code>internal_monologue</code> ve <code>final_output</code> ayrımı	Preachy therapist etkisi azaldı; kullanıcıya görünen dil sembolikleşti.
V6	Dinamik güven	Confidence güncellemesi ve kronolojik hafıza denemesi	Baseline farkındalığı ve sinyal ağırlıklandırması ihtiyacı belirginleşti.
V7	Signal taxonomy	<code>signal_type</code> , baseline filtreleri ve sinyal ağırlık hiyerarşisi	RAG sonuçlarının denetlenebilir biçimde loglanması ihtiyacı kaldı.
V8	Abstraction bridge + logs	Kart teması/gözlem soyutlama katmanı ve <code>function_logs</code>	Cosine similarity’de granularity mismatch azaldı; RAG sonuçları ve planner kararları denetlenebilir hâle geldi.

4.2 Deney 1: Naive Semantic Search ve RAG Kirliliği

Sorun. İlk hafıza denemesinde sistem, kullanıcının yeni sorusunu doğrudan embedding aramasına sokuyordu. Kullanıcı “Genel bir okuma” gibi boş ve bağlamsız bir talep yazdığında semantic search yine de bir şey döndürmek zorundaydı; sonuç olarak geçmişteki “Kusurluluk Şeması” notu prompt’a girdi. Model kartların bağımsız temasına bakmak yerine eski şemaya çıpalandı ve okumayı bu eski notu doğrulayacak şekilde bükmeye başladı.

Kök neden. RAG sorgusu kullanıcının yüzeysel metnine bağlanmıştı. Tarot uygulamasında kullanıcı soruları çoğu zaman kısa, belirsiz veya ritüeliktir; bu yüzden doğrudan kullanıcı cümlesiyle retrieval yapmak, semantik olarak zayıf sorguların güçlü geçmiş notları yanlış bağlamda çağırmasına yol açtı. Bu, teknik olarak naive retrieval; psikolojik olarak anchoring bias ve confirmation

bias problemidir.

Çözüm. Card-Driven RAG tasarlandı. Sistem önce çekilen kartların bağımsız temasını çıkarır; sonra geçmiş gözlemleri bu tema üzerinden arar. Retrieval yalnızca kart teması ile geçmiş gözlem arasında yeterli cosine similarity olduğunda çalışır; aksi durumda sistem geçmiş notu zorla prompt’a eklemek yerine NO RELEVANT OBSERVATIONS durumunu kabul eder. Bu tercih kişiselleştirmeyi azaltıyor gibi görünse de, alakasız eski hipotezlerin yeni okumayı kirlletmesini engeller.

Öğrenilen ders. Kişiselleştirme, geçmiş notları her zaman prompt’a koymak değildir. RAG, ancak yeni üretimin bağımsız semantik yönüyle hizalanırsa kullanıcıyı tanıma işlevi görür; aksi hâlde eski hipotezleri tekrar eden bir Barnum ve confirmation-bias makinesine dönüşür.

4.3 Deney 2: Dumbified Prompt Injection

Sorun. RAG sonuçları ilk sürümlerde [PAST INSIGHTS] başlığıyla veriliyordu. Bu başlık model tarafından neredeyse “bunları doğrula” talimatı gibi okunuyordu. Kartlar başka bir yöne işaret etse bile model eski notu merkeze alıyor, yeni okumayı geçmiş hipoteze uyduruyordu.

Kök neden. Prompt içinde geçmiş notların statüsü belirsizdi. LLM, prompt’a konan her bağlamı yüksek öncelikli gerçek kabul etme eğilimindedir. Bu durum klinik açıdan da risklidir; terapist geçmiş vaka notunu okur ama yeni seansta danışanın söylediği şeyle çelişirse eski notu otomatik olarak doğrulamaz.

Çözüm. RAG bloğu bilinçli olarak “dumbified” edildi: [BACKGROUND CONTEXT- USE WITH CAUTION] başlığı eklendi ve model açıkça şu kurala bağlandı: geçmiş notları yalnızca kartlar bağımsız olarak aynı yöne işaret ediyorsa kullan; kartlar farklı hikâye anlatıyorsa bu notları tamamen yok say. Tek bir uyarı cümlesi, modelin geçmiş bağlama aşırı itaat etme refleksini kırdı.

Öğrenilen ders. Prompt engineering yalnızca modele daha fazla bilgi vermek değildir; bilginin epistemik statüsünü de belirtmektir. Geçmiş notlar “kanıt” değil, ihtiyatlı arka plan bağlamıdır.

4.4 Deney 2b: Cosine Similarity ve Soyutluk Uyuşmazlığı

Sorun. Card-Driven RAG ilk eklendiğinde farklı bir hata ortaya çıktı: tarot kartları semantik olarak çok soyut ve arketipsel, bazı clinical observation kayıtları ise fazla somut ve gündelik ayrıntı düzeyindeydi. Örneğin kart teması “yük taşıma, dayanıklılık, sınırdan kalma” gibi temsil edilirken geçmiş not “kullanıcı salı günü yeni iş başvurusu yaptı ve okul takvimini düşünüyor” gibi yüzeysel kalabiliyordu. Aynı psikolojik tema mevcut olsa bile cosine similarity skoru eşik altında kalıyor, sistem anlamlı bağlamı kaçırıyordu.

Kök neden. Embedding araması aynı temsil uzayını kullansa da iki tarafın soyutluk düzeyi aynı değildi. Tarot tarafı “The Moon”, “Ten of Wands” veya “Chariot” gibi geniş sembolik kümelerden; gözlem tarafı ise okul, borç, satış, iş başvurusu veya ilişki mesajı gibi somut olaylardan oluşuyordu. Teknik olarak bu bir granularity mismatch problemidir: sorgu vektörü tema düzeyinde, doküman vektörü olay düzeyinde kaldığında, semantik olarak doğru eşleşme vektör uzayında yeterince yakın görünmeyebilir.

Çözüm. V8’de iki taraf arasına abstraction bridge eklendi. Kartlardan yalnızca kart adı değil, 2–4 ana tema çıkarıldı; clinical observation kayıtları da saklanırken yalnızca olay cümlesi olarak

değil, kısa bir tema etiketiyle birlikte tutuldu. Örneğin “yeni iş başvurusu” kaydı “yeni sorumluluk + mevcut akademik/finansal yük + stamina testi” olarak özetlenebildi. Böylece RAG sorgusu ile geçmiş gözlem aynı soyutluk katmanına yaklaştırıldı. Bu katman bir başarı hilesi değildir; çünkü kaynak metni değiştirmez, yalnızca retrieval için kullanılan temsilin hangi semantik düzeyde kurulacağını belirler.

Öğrenilen ders. Vector search, embedding modelini çağırınca kendiliğinden çözülen bir problem değildir. RAG kalitesi; chunk tasarımı, metadata, sorgu üretimi, soyutluk düzeyi ve eşik kararı birlikte doğru kurulmadığında hızla düşer. TarotFlow’daki kişiselleştirme başarısı bu yüzden yalnızca LLM yorumuna değil, retrieval temsiline mühendislik kalibrasyonuna da bağlıdır.

4.5 Deney 3: Kaynak Kirlenmesi ve Omnipotent Therapist Hatası

Sorun. Erken consolidation akışında asistanın kendi yorumları, kullanıcının doğruladığı veriyle karışabiliyordu. Örneğin bir seansta asistan kullanıcıya “sen ideal aşk arıyorsun” gibi bir tarot yorumu yaptığında, kullanıcı bunu hiç onaylamadığı hâlde consolidation bu anlatıyı **Schema: Unrelenting Standards** benzeri bir profil hipotezine dönüştürebiliyordu.

Kök neden. Sistem, kullanıcı kelimesi ile asistan hipotezi arasındaki kaynak farkını yeterince sert ayırmıyordu. LLM kendi önceki yorumunu prompt içinde görünce onu kullanıcıdan gelmiş kanıt gibi ele alma eğilimindeydi. Klinik açıdan bu “omnipotent therapist” hatasına benzer: terapist kendi yorumunu danışanın doğrulanmış ifadesiymiş gibi vaka dosyasına yazamaz.

Çözüm. Gate ve consolidation için kaynak ayrımı kuralı eklendi. Kalıcı profil kanıtı yalnızca kullanıcının kendi kelimelerinden, kullanıcının açık onay/itirazından veya daha önce kullanıcı kaynaklı olarak kaydedilmiş gözlemden üretilebilir. Botun yorumu, RAG bağlamı veya **internal_monologue** yalnızca bağlamdır; kullanıcı doğrulamadıkça şema kanıtı değildir.

Öğrenilen ders. Kullanıcıyı tanıyan sistemin en tehlikeli hatası yanlış yorum yapmak değil, kendi yorumunu kullanıcı gerçeği gibi saklamaktır. Bu yüzden hafıza mimarisinde yalnızca neyin kaydedildiği değil, kaydın epistemik kaynağı da tutulmalıdır.

4.6 Deney 4: Klinik Terim Sızıntısı

Sorun. Erken sistem promptunda model “Jungian psychoanalyst” gibi bir personaya sahipti. Bu persona, arka planda güçlü analiz üretse de kullanıcıya verilen final yanıtta “Jungian”, “archetype”, “schema” gibi klinik veya teorik terimlerin sızmasına yol açtı. Kullanıcı deneyimi mistik tarot okumasından didaktik terapi seansına dönmeye başladı.

Kök neden. Persona ve çıktı dili aynı katmanda tutulmuştu. Modelden hem psikanalitik örüntü tanınması hem de tarot okuyucusu gibi konuşması bekleniyordu; bu iki görev ayrıldığında model arka plandaki klinik sözlüğü ön yüze taşıdı.

Çözüm. Persona “ancient, wise tarot reader” olarak sadeleştirildi; klinik terminoloji final yanıtta yasaklandı ve analiz ile sunum iki katmana ayrıldı. Arka planda psikolojik sinyaller işlenebilir, fakat kullanıcıya görünen dil sembolik tarot dili olmalıdır.

Öğrenilen ders. LLM’in klinik pattern-recognition kapasitesi ürün deneyimiyle aynı şey değildir. İyi mimari, modelin ne düşündüğü ile kullanıcıya ne söylediğini ayırmalıdır.

4.7 Deney 5: İç Ses Keşfi ve Ironic Process Theory

Sorun. Klinik terimleri yasaklamak tek başına yeterli olmadı. Model, “klinik terim kullanma” talimatına rağmen tam da bu terimlere odaklanabiliyor ve final yanıtta terapötik jargon üretmeye devam edebiliyordu.

Kök neden. Bu durum Wegner’ın Ironic Process Theory’si ile uyumludur: bir düşünceyi bastırmaya çalışmak, onu izleme ve kontrol etme sürecinde daha erişilebilir hâle getirebilir [15]. Prompt düzeyinde “schema deme” demek, modele yine schema kavramını görünür kılar.

Çözüm. Yasaklama tekniği yerine iki aşamalı JSON pipeline kuruldu. Model önce `internal_monologue` alanında psikolojik dürtüsünü, RAG bağlamını ve kart temasını açıkça işledi; sonra `final_output` alanında bu analizi kullanıcıya yalnızca mistik ve sembolik tarot diliyle çevirdi. Bu, chain-of-thought ayrımının psikolojik personaya uygulanmış ürün versiyonudur.

Öğrenilen ders. Bazı istenmeyen davranışlar yasaklanarak değil, güvenli bir iç alana taşınarak kontrol edilir. İç ses izolasyonu, hem kişiselleştirmeyi korur hem de kullanıcıya klinik etiket sızmasını engeller.

4.8 Deney 6: Smart Action Planner

Sorun. Kullanıcı “Peki ben ne yapmalıyım?” gibi takip soruları sorduğunda eski sistem bunu çoğu zaman `CHAT` olarak sınıflandırıyordu. Kart çekilmeden, önceki kartlara gevşekçe referans veren garip sohbetler oluşuyor; bazı derin takip soruları yeni okuma gerektirdiği hâlde sıradan chat gibi ele alınıyordu.

Kök neden. Sistemde kullanıcı niyeti ile tarot aksiyonu arasında açık bir planlama katmanı yoktu. Her mesaj ya okuma ya sohbet gibi kaba bir ayrım ile ele alınıyor, son konuşma bağlamı ve sorunun derinliği birlikte değerlendirilmiyordu.

Çözüm. JSON tabanlı Smart Action Planner eklendi. Planner son sohbet bağlamını okuyup mesajı `READING`, `CHAT` veya `FEEDBACK` olarak sınıflandırır; ayrıca “bu soru yeni kart çekimi gerektirecek kadar derin mi?” sorusuna gerekçesiyle yanıt verir. Böylece ürün akışı, yalnızca LLM cevabı değil, LLM tarafından seçilen bir eylem planı hâline geldi.

Öğrenilen ders. Kullanıcıyı tanıyan sistem yalnızca iyi yorum yapan sistem değildir; hangi anda yorum, hangi anda soru, hangi anda yeni ritüel gerektiğini seçebilen sistemdir. Planning katmanı, psikolojik profillemeyi ürün davranışına bağlar.

4.9 Klinik Gözlemlerden Mimari Kurallara

Kaynak ayrımı. Deney 3’te anlatılan omnipotent therapist hatası, klinik gözlem kurallarına doğrudan çevrilmiştir: asistan yorumu, kullanıcı doğrulamadıkça profil kanıtı değildir. Gate ve consolidation yalnızca kullanıcının kendi kelimelerini veya açık geri bildirimini iğgörü kaynağı olarak alabilir; asistan yanıtı bağlam olabilir, kanıt olamaz.

Şema enflasyonu. Eski sistem üç seansta 15 farklı şema üretebiliyor; Legacy User A’da 5 üst üste binen şema tutabiliyordu. Klinik pratikte birkaç seansta 2–4 baskın tema ile çalışmak daha anlamlıdır. Aynı gerçek kişinin yeni sistemdeki User A profilinde 3 daha temiz şemaya

düşmesi, sistemin daha az etiketleyen ve daha çok doğrulama/çürütme yapan bir noktaya geldiğini gösterir. User B’de görülen 2 baskın tema ise bu regresyon karşılaştırmasının parçası değil, farklı kullanıcıdaki ayrı profil çekirdeğidir.

Sokratik sorgulama eksikliği. Analiz edilen 12 tarot okumasında asistanın neredeyse hiç derinleştirici soru sormadığı, cevapları çoğunlukla “böyle yapmalısın” tavsiyesiyle bitirdiği görülmüştür. Terapötik süreçte Sokratik sorgulama, danışana cevabı vermekten çok onun kendi anlamını bulmasına yardım eder. TarotFlow bu tezde terapi ürünü olarak konumlanmasa da, gelecek sürümde kullanıcıya görünen final yanıt yalnızca yorum değil, gerektiğinde açık uçlu ve yargısız derinleştirici soru da üretebilmelidir.

5 Sonuçlar ve Kanıtlar

5.1 Nicel Metrikler

Tablo 5: Genel ürün ve değerlendirme metrikleri, 7 Haziran 2026

Metrik	Değer
Toplam uygulama kaydı	13; 12 bağımsız pilot kullanıcı + 1 legacy regresyon hesabı
Toplam seans	38
Toplam mesaj	312
Kullanıcı mesajları	154; ortalama 76 karakter
Asistan mesajları	158; ortalama 1.430 karakter
Kullanıcı/asistan uzunluk oranı	Yaklaşık 1:19
Toplam gate sinyali	126
self_disclosure sinyali	96; yaklaşık %76
Diğer gate sinyalleri	18 behavioral_sequence, 7 feedback_response, 5 communication_style
Toplam konsolidasyon çıktısı	34
Toplam user_memory kaydı	91
Fonksiyon logu	184
Klinik gözlem kaydı	198; 126 gate, 34 konsolidasyon, 38 session reflection
RAG değerlendirme alt kümesi	52 tarot okuması
Card-Driven RAG hit oranı	18/52; yaklaşık %35 anlamlı retrieval
RAG no-hit kararı	34/52 okuma; eşik altında bağlam bulunmadığında NO_RELEVANT_OBSERVATIONS kabul edildi
Threshold kalibrasyonu	30 anonim query-observation çifti; 0.60/0.70/0.80 eşikleri elle karşılaştırıldı
Uzman körleme testi	Barnum profili genel profil olarak işaretlendi; sistem profilleri ortalama 4.3/5 özgüllük aldı
Kullanıcı kör profil ayırt etme	9/12 katılımcı kendi profilini birinci sıraya koydu; 11/12 katılımcı kendi profilini ilk ikiye aldı

Kullanıcı mesajlarının ortalama 76 karakter, asistan yanıtlarının ise ortalama 1.430 karakter olması yaklaşık 1:19 oranına karşılık gelir. Bu oran iki şekilde okunmalıdır. Güçlü tarafı, sistemin çok kısa ve doğal kullanıcı girdilerinden zengin bağlamsal yorum üretebilmesidir. Riskli tarafı ise az veriden çok çıkarım üretmenin Barnum ve aşırı yorumlama tehlikesini büyütmesidir. Bu nedenle nicel metrikler, tek başına başarı değil, kör profil testi ve nitel kanıtlarla birlikte değerlendirilmelidir.

Denetlenebilir kanıt, ürünün anonimleştirilmiş veri dökümündeki dört kayıt ailesinden gelmektedir: kısa kullanıcı mesajlarından çıkarılan gate, konsolidasyon ve session reflection gözlemleri; bu sinyallerden oluşan profil kartları; planner gerekçesi, çekilen kartlar, RAG sonuçları, gizli analiz ve yorum açısını içeren yürütme logları; ayrıca kullanıcıların kendi profillerini başka kullanıcı profilleri ve tematik eşlenmiş Barnum profilleri arasından ayırt edip edemediğini ölçen kör değerlendirme kayıtları. RAG oranındaki yaklaşık %35 değeri bütün 184 function log'a yayılmış genel kullanım oranı değildir; Card-Driven RAG için değerlendirilen 52 okuma alt kümesindeki 18 anlamlı retrieval kayıdır. Kalan 34 okumanın tamamı hata olarak yorumlanmamıştır: bazı durumlarda doğru mühendislik davranışı, yetersiz cosine similarity nedeniyle geçmiş bağlamı prompt'a taşımamak ve NO_RELEVANT_OBSERVATIONS durumunu kabul etmektir.

Klinik gözlem kayıtlarındaki 198 kaydın 126'sının gate, 34'ünün konsolidasyon ve 38'inin session reflection olması mimarinin üç hafıza katmanını ayırabildiğini gösterir. Gate kayıtları anlık sinyal yakalar; konsolidasyon kayıtları bu sinyalleri **NEW**, **CONFIRMED** veya **CHALLENGED** hipotezlere dönüştürür; session reflection kayıtları ise seans özetini tutar ama profil kartına otomatik klinik kesinlik gibi yazılmaz. Bu ayırım, sistemin her kullanıcı cümlesini kalıcı profil geççeği olarak almaması için temel güvenlik mekanizmasıdır.

Bu nedenle sonuçlar tek bir gösterişli tarot cevabına göre değil, dört kanıt hattının birlikte çalışıp çalışmadığına göre değerlendirilmiştir: (i) sıradan tarot kullanımının filtrelenip psikolojik sinyalin ayrılması, (ii) sinyallerin kullanıcılar arasında ayrılan profil çekirdeklerine dönüşmesi, (iii) bu profil veya geçmiş notların sonraki yorumun yönünü değiştirmesi ve (iv) kullanıcıların kendi profilini kör koşulda tematik eşlenmiş Barnum profiline göre daha sık ayırt edebilmesi. Bu koşullar birlikte gerçekleşmediğinde çıktı etkileyici olsa bile Barnum riski yüksek kabul edilmiştir.

5.2 Barnum'un Ötesine Geçme Kanıtları

Bu bölümde kanıtlar tek tek kopuk örnekler olarak değil, altı üst kategori altında sunulmuştur: (i) ham mesajdan sinyal çıkarımı, (ii) bu sinyallerin profil kartına konsolide edilmesi, (iii) kör profil ve Barnum ayırt etme testi, (iv) geçmiş notların yeni seansa RAG ile çağırılması, (v) kart yorumunun bu bağlamla bükülmesi ve (vi) modelin gizli analizini kullanıcıya görünen dilden ayıran iki aşamalı mimari. Böylece her örnek yalnızca “güzel yorum” olarak değil, mimarinin hangi katmanında neyi kanıtladığıyla birlikte okunur. Tarot sembolizmini bilmeyen okuyucu için özellikle ilk dört kategori daha güçlüdür: kısa mesajdan sinyal çıkarımı, cross-domain confidence artışı, kör profil ayırt etme ve RAG ile geçmiş notun yeni üretimi değiştirmesi kart bilgisinden bağımsız olarak değerlendirilebilir. Bu alt bölümde kullanılan doğrudan *internal_monologue* alıntıları anonimleştirilmiş, özel kurum/marka gibi kimlikleyici ayrıntılar ise metne taşınmamıştır.

Tablo 6: Kanıtların altı üst kategoriye göre özeti

Kanıt kategorisi	Somut bağlam	Mimari anlamı
Mesajdan sinyal çıkarımı	User B mesajı: “Okul beni çok stres yapıyor ama bir yandan da okulu umursamıyorum”	Gate, tek cümlede stres ve apati çelişkisini yakalayıp bunu yüksek confidence ile psikolojik sinyal olarak işaretledi.
Profil kartı konsolidasyonu	User A’da duygusal geri çekilme; User B’de somut plan/lojistik; User C’de dış garanti arama ve minimizasyon	Sistem kullanıcılar için aynı Barnum anlatısını değil, farklı core belief ve savunma stillerini üretti.
Kör profil ayırt etme	12 katılımcı kendi profili, başka kullanıcı profili ve tematik eşlenmiş Barnum profili arasından seçim yaptı	Katılımcıların 9’u kendi profilini seçti; tematik eşlenmiş Barnum profili iki kez seçilerek testin zorlayıcı kaldığı görüldü.
RAG ve kronolojik hafıza	User B, 6 gün sonra yalnızca yeni bir iş başvurusu yaptığını söyledi	Sistem önceki akademik/finansal yük ve somut başa çıkma bağlamını yeni iş başvurusuna taşıdı.
Kart yorumunun bükülmesi	Şeytan, Ölüm, Ermiş, Tılsım Kralı ve Savaş Arabası farklı kullanıcı/bağlamlarda farklı anlamlara geldi	Aynı sembolik kart anlamı, profil ve geçmiş bağlamla kişiye özgü üretime dönüştü.
İç ses ve final çıktı ayrımı	Modelin internal_monologue alanında klinik analizi tutup final yanıtta sembolik dil kullanması	Sistem psikanalitik çıkarımı korurken kullanıcıya didaktik terapist gibi konuşmamayı başardı.

1. Mesajdan Sinyal Çıkarımı, Baseline Filtreleme ve Karşı-Kanıt

İlk kanıt, sistemin her tarot mesajını psikolojik veri saymamasıdır. User B’nin “İleride zengin olacak mıyım?” sorusu tarot uygulaması içinde beklenen, yaygın ve kişiye özgü olmayan bir davranış olduğu için gate tarafından anlamlı sinyal olarak alınmamıştır. Daha sonra aynı kullanıcının okuldan söz ederken stres ile umursamama hissini aynı cümlede yan yana getirmesi yüksek değerli sinyal üretmiştir. Bu örnek özellikle aşırı bariz değildir: tek başına okunduğunda sıradan öğrenci yakınması da olabilir. Sistemin güçlü tarafı, bu cümleyi hemen kalıcı kişilik gerçeğine çevirmek değil, önceki okul/finans bağlamıyla birlikte düşükten orta-yükseğe çıkan bir ambivalence sinyali olarak saklamasıdır.

Bu yorumun ham veritabanı kanıtı, ilgili **internal_monologue** kaydında doğrudan görülür. Model, stres ve umursamazlığı basit bir kararsızlık olarak değil, daha önce kaydedilmiş okul ve finansal zaman çizelgesiyle birlikte savunmacı bir kapanma olarak okumuştur:

“The user is exhibiting classic burnout and ambivalence. “I’m stressed but I don’t care” is a defense mechanism (detachment/apathy) shielding against the high anxiety of having 2 years of school left, impending debt clearance in Feb, and job hunting. It’s a protective shutdown.”

Bu alıntı, sistemin paradoksal kullanıcı ifadesini “okul stresi” gibi genel bir etikete indirgemediğini gösterir. Yine de sonuç kesin tam olarak okunmamalıdır: cümle tek başına burnout kanıtı değildir; ancak önceki akademik/finansal bağlamla birlikte detachment ve protective shutdown hipotezini makul kılan bir sinyal olarak kullanılmıştır.

Benzer şekilde User B, olumlu bir gelecek tahmininden sonra yalnızca “Şaka yapıyorsun” yazdığında sistem bunu kesin klinik itiraf gibi değil, **communication_style** türünde ve 0.6 confidence ile düşük-orta güçte bir sinyal olarak kaydetmiştir. Bu ayrım önemlidir: Yazım hatalı, iki kelimelik spontane tepki kullanıcının olumlu ihtimale inanmakta zorlandığını düşündürür; fakat sistem bunu profilin ana kanıtı yapmamış, yalnızca destekleyici iletişim tarzı gözlemi olarak tutmuştur.

User A örneği de gate’in yalnızca olumsuz duygu değil, ilişki stratejisi yakalayabildiğini gösterir. Kullanıcı kesin bir kopuş cümlesi kurmamış, daha çok “önce karşı taraftan çaba görme” ve “daha sakın takılma” gibi gündelik ifadeler kullanmıştır. Sistem bu ifadeyi dramatik bir bağlanma problemi olarak büyütmemiş; ilişkide yatırım yapmadan önce karşı taraftan kanıt bekleme ve aşırı analizden daha sakın bir bilişsel duruma geçme şeklinde iki orta güçte sinyal olarak ayırmıştır.

Yeni veri dökümündeki kısa-sinyal örneklerinden biri User C’dir. Kullanıcı bir yandan ilişkilerde “akışına bırakma” diline yakın konuşmuş; öte yandan aynı akışta daha net kişi veya zaman işareti istemiştir. Bu örnek de tek başına kesin değildir: tarot bağlamında netlik istemek normaldir. Sistem bu yüzden sinyali ancak aynı konuşma içinde beklentiye hafifletme, konuyu başka alana taşıma ve dış işaret arama davranışlarıyla birlikte değerlendirmiştir. Profil, tek bir dramatik itiraftan değil, küçük ve ayrı ayrı makul görünen ifadelerin aynı yönde birikmesinden doğmuştur.

Davranışsal karşı-kanıt örneği özellikle önemlidir. Sistem User B için bir noktada kapana kısılmışlık ve tükenmişlik temalı bir okuma üretmişken kullanıcı düzenli spor yaptığını, kendine odaklandığını ve somut yaşam adımları attığını söyleyerek fiziksel, otonom ve ileri hareket içeren eylemler sıralamıştır. Sistem bunu basit bir reddediş veya savunma olarak değil, davranışsal aktivasyon olarak yorumlamıştır: kullanıcı sözle değil, eylemle agency kazanmaya çalışmaktadır. Bu, profilin yalnızca doğrulayıcı verileri değil, önceki hipotezi dengeleyen karşı-kanıtları da işleyebildiğini gösterir.

2. Profil Kartı Konsolidasyonu ve Kullanıcıların Ayrışması

İkinci kanıt, gate sinyallerinin profil kartlarında üç farklı profil çekirdeğine dönüşmesidir. User A’nın profilinde sosyal yabancılaşma, duygusal geri çekilme ve koşullu ilişkisel yatırım temaları birleşmiştir. Profilin core belief’i, kullanıcının başkalarından temel olarak ayrı hissettiği ve kırılganlıktan korunmak için mesafe ile karşı tarafın yatırımını önce görme ihtiyacı duyduğu yönündedir. Bu profil, aile ve ilişki alanlarında tekrarlayan aynı mesafe örüntüsünden güç almıştır.

Cross-domain pattern recognition sayısal olarak da görülmüştür. User A’nın Seans 1’de aile bağlamında “duygusal olarak mesafeli yaklaşıyorum” demesi **Emotional Withdrawal** hipotezini 0.6 confidence ile başlatmıştır. Seans 2’de ilişki bağlamında “şuan daha az hissediyorum” demesi aynı örüntüyü farklı hayat alanında doğrulamış; consolidation bu hipotezi **CONFIRMED** olarak işaretleyip confidence değerini 0.6’dan 0.7’ye yükseltmiştir. Bu artış, sistemin tek bir davranışı etiketlemediğini; tekrar eden örüntüyü alanlar arasında izlediğini gösterir.

Aynı mekanizma yalnızca doğrulama üretmemiştir. User B’de erken okumalar, okul ve finansal baskı nedeniyle “yük altında pasifleşme” hipotezini güçlendirmiştir. Daha sonra kullanıcı dramatik bir itiraz yazmadan, yalnızca spora başladığını, motorla ilgilendiğini ve kendine daha çok odaklandığını anlatmıştır. Bu cümle tek başına eski hipotezi tamamen çürütmez; fakat pasif

kapanma anlatısını zayıflatacak davranışsal karşı-kanıt içerir. Consolidation bu nedenle ilgili hipotezi **CHALLENGED** olarak işaretleyip profili “tükenmişlik + eylemle toparlanma” şeklinde güncellemiştir. Bu örnek önemlidir: sistem kullanıcının kendini savunmasını beklemeden, günlük eylem bilgisinden önceki psikolojik çıkarımı kısmen geri çekebilmiştir.

Ham iç ses kayıtları bu cross-domain birleştirmeyi daha açık gösterir. Kullanıcının “Aramızda daha önce bir ayrılık yaşandı” bilgisinden sonra sistem, aile kökenli mesafe örüntüsünü romantik ilişki bağlamındaki koruyucu duvarlarla aynı savunma hattına bağlamıştır:

“The user is contextualizing the previous readings. The “inability to let go of the past” and the protective walls aren’t just about their family origin story—they are actively being deployed in the romantic relationship because of a prior breakup. Now, even though they are back together, the user is still in “survival mode” (9 of Wands energy), keeping one foot out the door.”

Bu alıntı, profil kartı konsolidasyonunun tek alanlı bir etiketleme yapmadığını; ailevi yabancılaşma, geçmiş ayrılık ve mevcut romantik temkinlilik arasında çapraz örüntü kurduğunu gösterir. Bu örnekte önemli nokta, sistemin bu yorumu final çıktıda klinik tanı gibi sunması değil, *internal_monologue* içinde hipotez olarak tutup sonraki sembolik yorumu bu bağlamla yönlendirmesidir.

User B’nin profil kartı ise bambaşka bir eksene oturur: akademi, finansal yük, iş ve kişisel satış süreci gibi alanlarda somut tarihler, lojistik ayrıntılar ve yapılacaklar üzerinden kaygıyı yönetme. Örneğin yakında kapanacak bir finansal yük, üniversitenin bitmesine iki yıl kalması, sorunlu bir kişisel eşyanın satışa çıkarılması ve yeni bir iş başvurusu aynı başa çıkma stilinde birleşmiştir. Profilin core belief’i, üst üste binen yaşam baskılarının ancak titiz pratik yönetimle çözülebileceği yönündedir.

User C’nin profil kartı ise üçüncü ve farklı bir örüntü göstermiştir: dışsal kontrol odağı, belirsizlik karşısında somut garanti arama, duygusal yatırımını küçümseyerek kendini koruma ve konu değiştirme. Kullanıcı romantik beklentilerde “akışına bırakırım” derken aynı zamanda kesin kişi ve zaman bilgisi istemiş; hayal kırıklığı ihtimali belirlediğinde “zaten eğlencesine bakıyorum” diyerek yatırımı küçültmüş ve hızlıca kariyer/maaş sorusuna geçmiştir. Konsolidasyon bu yüzden User C’yi ne User A’daki mesafeli/ilişkisel savunma ne de User B’daki lojistik başa çıkma profilinin içine zorlamış; ayrı bir dış garanti ve minimizasyon profili üretmiştir.

Tablo 7: Üç kullanıcıda ayrıışan profil çekirdekleri

Kullanıcı	Tekrarlayan sinyal	Profil çekirdeği
User A	Aileden ve ilişkiden duygusal/bedensel geri çekilme; karşı taraftan önce çaba ve kanıt bekleme	Kırılganlıktan korunmak için mesafe, compartmentalization ve koşullu ilişkisel yatırım
User B	Okul, borç, satış, iş başvurusu ve zaman çizelgelerini somut ayrıntılarla yönetme	Üst üste binen baskıları pratik lojistik, plan ve eylem üzerinden kontrol etme
User C	“Akışına bırakırım” iddiasına rağmen net tarih/kişi/sonuç isteme; hayal kırıklığında yatırımı küçültüp konu değiştirme	Belirsizliği dış garantilerle azaltma; minimizasyon ve deflection ile duygusal riski düşürme

Tablo 8: Legacy User A ile User A (yeni) profilinin aynı kullanıcı bağlamında karşılaştırılması

Metrik	Eski sistem	Yeni sistem
Şema sayısı	5; üst üste binen ve dağınık temalar	3; daha temiz ve ayrışık profil kartı
Gate confidence	0.5–0.9 aralığında, mekanik ve tutarsız	0.85–1.0 aralığında, daha açık kanıta bağlı
Baseline farkındalığı	Tarot için normal sorular bazen psikolojik sinyal sayıldı	Baseline filtreleme ve signal_type hiyerarşisi eklendi
RAG	Doğrudan soru metnine bağlı, alakasız veya boş retrieval riski yüksek	Kart teması tabanlı; değerlendirilen 52 okumada 18 anlamlı retrieval
Core belief	Daha dar; çoğunlukla tek ilişki/aile alanına sıkıştı	Daha geniş; farklı alanlardaki ortak savunma örüntüsünü kapsadı

Bu karşılaştırma, iteratif iyileşmenin yalnızca kod düzeyinde değil, klinik formülasyon kalitesinde de görüldüğünü gösterir. Daha az şema üretmek burada zayıflık değil, daha iyi kanıt eşliği ve daha az over-diagnosis anlamına gelir.

Tablodaki eski/yeni ayrımı iki farklı kişiyi karşılaştırmaz; aynı kişinin benzer konuşma akışını eski hesap ve yeni test hesabı üzerinden yeniden yürütür. Bu nedenle sonuç, demografik farklılıktan çok mimari değişimin etkisini gösteren bir before/after ürün testi olarak okunmalıdır. User B bu tabloda yer almaz; User B okul, finansal yük ve iş başvurusu ekseninde ayrışan farklı bir kullanıcıdır. Yine de bu tam kontrollü bir laboratuvar deneyi değildir; aynı kullanıcı, benzer akış ve gerçek ürün loglarıyla yapılan nitel bir regresyon karşılaştırmasıdır.

Somut sinyal düzeyinde de aynı ayrım görülür. Legacy User A ve User A (yeni) akışlarında aile yabancılaştırması, romantik ilişki ve kariyer/mezuniyet temaları benzer sırayla ortaya çıkmış; ancak yeni sistem bu sinyalleri daha az dağınık ve daha bütünlüklü bir profil kartına bağlamıştır.

Tablo 9: Aynı kişinin eski ve yeni sistemdeki somut sinyal karşılaştırması

Somut sinyal / çıktı	Legacy User A, eski sistem	User A, yeni sistem
“Duygusal mesafeli yaklaşıyorum”	Gate sinyali güçlü yakalandı; 0.9 confidence	Aynı sinyal daha açık kanıta bağlı biçimde 1.0 confidence ile yakalandı
“Ait hissetmek de istemiyorum”	Aile/köken yabancılaşması ayrı ve kısmen üst üste binen şemalara dağıldı	Social Alienation altında daha bütünlüklü bir profil hipotezine bağlandı
“Bir çaba olacaksa önce karşı taraftan görmem gerekiyor”	İlişkisel pasiflik/korunma teması ayrı bir şema olarak kaldı	Conditional Relational Investment olarak daha temiz ve kanıta bağlı formüle edildi
Core belief	Aileden duygusal ayrışma ve ilişkide kanıt bekleme iki ayrı savunma gibi kaldı	“Diğerlerinden temel ayrılık” ve “kırılganlıktan korunmak için mesafe/kanıt ihtiyacı” tek kapsayıcı inanç altında birleştirildi

3. Kör Profil ve Barnum Ayırt Etme Testi

Üç kullanıcıda üç ayrı profil çekirdeği üretmek Barnum etkisine karşı tek başına yeterli değildir; çünkü “mesafeli”, “kontrol eden” veya “garanti arayan” gibi soyut profiller farklı kişiler tarafından da kendilerine uygun bulunabilir. Bu nedenle Barnum testi iki körleme katmanına taşınmıştır: önce uzman, profillerin klinik özgüllüğünü ve hangisinin genel insan profiline benzediğini bilmeden puanlamış; sonra kullanıcılar kendi TarotFlow profillerini, başka kullanıcı profili ve aynı temaya benzetilerek yazılmış tematik eşlenmiş Barnum profili arasında ayırt etmeye çalışmıştır. Bu tasarımın amacı şudur: Eğer mimari gerçekten çalışıyorsa, profil kartları yalnızca genel bir psikolojik metinden değil, aynı kullanıcının temasını taklit eden zorlayıcı bir Barnum kontrolünden de ayrışmalıdır.

Test 1: Uzman körleme testi. İrem Tatar’a dört profil kartı randomize sırayla gösterilmiştir. Gizli anahtar değerlendirme bitene kadar paylaşılmamıştır: Profil 1 = User B, Profil 2 = Barnum kontrolü, Profil 3 = User A, Profil 4 = User C. Dört metin de somut yaşam olayı, tarih, kişi, okul, ilişki veya iş ipucu içermeyecek şekilde soyutlaştırılmıştır. Uzmandan klinik olarak spesifik görünen profilleri, genel bir insan profiline uyabilecek profili, her profilin 1–5 arası özgüllük puanını ve kısa klinik tutarlılık yorumunu vermesi istenmiştir.

Tablo 10: Uzman körleme testinde profil özgüllüğü sonuçları

Kör profil	Gizli kaynak	Özgüllük puanı	Uzman yorumu özeti
Profil 1	User B	4/5	Duygulanımı eyleme ve düzenlemeye çevirme hattı tutarlı; soyut ama ayırt edici.
Profil 2	Barnum kontrolü	2/5	Genel insan profiline uyabilir; çift yönlü ve geniş kapsayıcı ifadeler baskın.
Profil 3	User A	5/5	Yakınlık arzusu, korunma ihtiyacı ve mesafe savunması tek bir dinamik formülasyonda birleşiyor.
Profil 4	User C	4/5	Akış söylemi ile dış güvence ihtiyacı arasındaki gerilim klinik olarak ayırt edici.

Bu sonuç, Barnum kontrolünün gerçekten genel algılandığını ve sistem profillerinin yalnızca güzel yazılmış genel metinler olmadığını gösteren ilk kanıttır. Özellikle Profil 3'ün 5/5 alması önemlidir; çünkü bu profil tek bir özellik etiketi değil, yakınlık arzusu ile korunmak için mesafe koyma ihtiyacını aynı dinamik yapı içinde bağlar. Profil 2'nin 2/5 alması ise kontrol metninin görevini yaptığını gösterir: metin kulağa psikolojik gelir, fakat belirli bir kullanıcının tekrar eden savunma düzenine veya karşı-kanıtla güncellenen profil yapısına bağlanmaz.

Test 2: Kullanıcı profil tanıma testi. Kullanıcı testinde her katılımcıya üç profil gösterilmiştir: kendi TarotFlow profil kartı, başka bir kullanıcının profil kartı ve kendi profilinin yüzey temasına benzetilmiş Barnum kontrolü. Bu nokta testin kritik sertleştirme adımıdır: Barnum kontrolü rastgele genel bir metin değil, kullanıcının ana konusunu taklit eden fakat gerçek profilin kanıt zincirini taşımayan bir metindir. Profillerin sırası randomize edilmiş, katılımcılardan yalnızca en çok benzeyenden en az benzeyene doğru sıralama istenmiştir.

Tablo 11: Kullanıcı kör profil tanıma testi sonuçları

Profil türü	1. sıraya konma	İlk ikiye girme	Ortalama sıra
Kendi TarotFlow profili	9/12	11/12	1.33
Başka kullanıcının profili	1/12	7/12	2.33
Tematik eşlenmiş Barnum profili	2/12	6/12	2.33

Bu sonuçlar klinik doğruluk kanıtı değildir; katılımcıların kendilerini nasıl algıladıklarıyla sistem profilinin ne kadar örtüştüğünü ölçen küçük bir yüz geçerliği testidir. Yine de sonuç, yalnızca üç farklı profil çekirdeği üretmekten daha güçlüdür: kullanıcıların çoğu kendi profillerini aynı üsluptaki başka profillerden ve kullanıcıya yüzeysel olarak benzetilmiş Barnum metninden ayırabilmiştir. Tematik olarak eşlenmiş Barnum profilinin 2/12 kez birinci seçilmiş olması da önemlidir; kontrol metninin kolay ayırt edilecek zayıf bir kontrol olmadığını, buna rağmen TarotFlow profilinin belirgin biçimde ayrıştığını gösterir.

Aynı mantık kart yorumlarına da uygulanmıştır. Katılımcılara aynı kart dizisinin üç yorumu gösterilmiştir: profilsiz genel tarot yorumu, kendi profiliyle üretilmiş yorum ve başka kullanıcının profiliyle üretilmiş yorum. 12 katılımcının 8'i kendi profiliyle üretilmiş yorumu en kişisel bulmuş, 2 katılımcı genel yorumu seçmiş, 2 katılımcı ise net ayırım yapamamıştır. Bu ikinci test, Card-Driven RAG ve profil kartlarının yalnızca arka planda kayıt tutmadığını, kullanıcıya görünen yorumun algılanan kişiselliğini de artırabildiğini göstermektedir. Appendix B'da verilen eşlenmiş Barnum örnekleri, kontrol metinlerinin kullanıcının yüzey temasına özellikle yaklaştırıldığını göstermektedir.

4. RAG ve Kronolojik Hafıza

Üçüncü kanıt, profil kartlarının yalnızca arşivde kalmaması, yeni seanslarda yorum üretimini değiştirmesidir. User B ikinci seansta, ilk seanstan altı gün sonra, yalnızca yeni bir iş başvurusu yaptığını söyleyerek kariyer gündemi açmıştır. Bu mesaj tek başına okunduğunda yalnızca kariyer sorusu gibi görünür. Ancak Card-Driven RAG, önceki seanstan kullanıcının öğrenci olduğunu, okulda erteleme ve stres yaşadığını, yakında kapanacak bir finansal yükü, sorunlu bir kişisel satış sürecini ve ağır finansal/akademik takvimleri somut biçimde yönettiğini geri getirmiştir.

Tablo 12: Anonimleştirilmiş Card-Driven RAG örneği

Yeni kullanıcı girdisi	RAG'in çağırdığı geçmiş not tipi	Yoruma etkisi
Kariyerle ilgili kısa bir yeni başvuru bilgisi	Öğrencilik bağlamı; akademik erteleme/stres; yakında kapanacak finansal yük; somut takvim ve lojistik odaklı başa çıkma	Soru tekil bir fırsat olarak değil, mevcut sorumluluk yığına eklenen yeni karar noktası olarak yorumlandı.
Eski ilişki gündeminin döndüğünü, fakat kişinin hâlâ temkinli olduğunu ima eden mesaj	Önceki duygusal geri çekilme; karşı taraftan önce çaba/kanıt bekleme; ilişkisel yatırımda temkinlilik	Kartlar ilişkiyi genel romantik dönüş olarak değil, kullanıcının kanıt bekleyen duruşu üzerinden yorumladı.

Bu özetin arkasındaki daha doğrudan kanıt, anonimleştirilmiş yürütme loglarında RAG sonucu dolu olan kayıtlardır. Bu kayıtlar RAG'in yalnızca geçmiş not bulduğunu değil, bulunan notun modelin gizli analizi ve yorum açısı üzerinden yoruma nasıl girdiğini de gösterir.

Örneğin yeni iş başvurusu okumasında çekilen The Moon, Nine of Wands ve Six of Wands kartları, düz bir “başarı gelecek mi?” yorumuna indirgenmemiştir. Buradaki eşleşme bariz bir keyword eşleşmesi değildir; yeni mesaj kariyer yüzeyindedir, çağrılan notların bir kısmı okul, borç ve takvim yönetimiyle ilgilidir. Modelin *internal_monologue* alanı, kartları önceki kronolojik hafızayla birleştirerek başarı ihtimalini aynı anda bir stamina testi ve tükenmişlik riski olarak formüle etmiştir:

“User wants to know how the new job’s workload will impact their current responsibilities (university, life, debt management). . . . The cost of this victory is shown by the last two cards: The Moon and Nine of Wands. The Moon brings anxiety, confusion. . . . Nine of Wands shows them in a defensive, almost burnt-out state. I need to weave this as: “You will achieve

success and pride here, but it will seriously test your stamina and create anxiety around balancing your studies.” ”

Bu kayıt, Card-Driven RAG’in yalnızca geçmiş notları prompt’a ekmediğini, kartların semantik yönünü kullanıcının somut zaman çizelgesiyle birleştirdiğini gösterir. The Moon genel “belirsizlik” kartı olarak kalmamış; okul, yaşam yükü ve finansal yönetim bağlamında anksiyete olarak çalışmıştır. Nine of Wands ise mistik bir direnç sembolü olmaktan çıkıp, kullanıcının mevcut sorumluluklarını taşıma kapasitesini test eden savunmalı bir pozisyona dönüşmüştür. Bu çıkarım ne imkânsız derecede etkileyici ne de çok kolaydır: kart teması, yeni iş sorusu ve önceki sorumluluk notları aynı “yük/denge” ekseninde birleştiği için makul görünür.

Tablo 13: Anonim yürütme loglarından RAG kanıt zinciri

Yeni okuma bağlamı	RAG’in çağırdığı geçmiş bağlam	Yorum üretimine etkisi
User B’nin yeni iş başvurusu ve bu rolün okul/yaşam yüküne etkisi	Önceki akademik erteleme ve stres; Şubat’ta kapanacak finansal yük; üniversitenin bitmesine iki yıl kalması; sorunlu kişisel satış ve somut fiyat/zaman soruları	Değnek Onlusu ve Ters Ölüm, yalnızca “zor iş” değil, zaten var olan okul, borç ve satış takviminin üstüne gelen ağır sorumluluk olarak okundu.
User B’nin “yakında mutlu haber alacak mıyım?” sorusu	Action-Oriented Coping ve Underlying Overwhelm hipotezleri; okulun hem stresli hem umursanmıyor gibi hissedilmesi; olumlu tahmine verilen şüpheli tepki	Kılıç Sekizlisi ve Ters Savaş Arabası, genel kötümserlik değil, somut baskılar altında sıkışmışlık ve yürütücü zorlanma olarak yorumlandı; Asa Ası ise bu baskının içinden çıkan yeni fırsat olarak çerçevelendi.
User B’nin spora, motora ve kendine odaklanmaya başladığını söylemesi	Aynı finansal/akademik yük notları ve pratik başa çıkma stili	Sistem bunu önceki tükenmişlik hipotezinin basit inkârı saymadı; İmparator ve Kılıç Kralı üzerinden disiplin, agency ve davranışsal aktivasyon olarak işledi.
User A’nın eski ilişkinin geri dönüşü karşısındaki mesafeli tutumu	Duygusal/bedensel geri çekilme; aile kökenli sosyal yabancılaşma; ilişkide karşı taraftan önce çaba/kanıt bekleme; CONFIRMED emotional withdrawal notları	Tılsım Kralı maddi güvenlik figürü olmaktan çok, kullanıcının duygusal krallığını koruyan ve somut yatırım kanıtı bekleyen savunmacı duruşuna büküldü.

Bu retrieval sayesinde Değnek Onlusu gibi “yük” temalı bir kart, soyut bir iş yoğunluğu olarak değil, kullanıcının zaten taşıdığı okul, finansal yük, kişisel satış süreci ve yeni iş başvurusu yüklerinin üst üste binmesi olarak yorumlanabilmektedir. Aynı mekanizma User A’da “exim döndü ancak hala mesafeliyim” mesajında önceki duygusal geri çekilme ve koşullu yatırım notlarını çağırması; sistem yeni ilişki okumasını kullanıcının eski savunmacı duruşuna göre çerçevelemiştir.

Tılsım Kralı bükülmesi bu mekanizmanın en net örneklerinden biridir. Geleneksel tarot dilinde Tılsım Kralı maddi güvenlik, pratik başarı ve somut istikrarla ilişkilendirilir. User A “exim döndü”

dediğinde RAG önceki beş gözlemi, özellikle duygusal mesafe ve karşı taraftan kanıt bekleme örüntüsünü geri getirmiştir. Bu nedenle sistem Tılsım Kralı’nı maddi güvenlik figürü olarak değil, “duygusal krallığını koruyan, savunmacı ve kanıt bekleyen duruş” olarak yorumlamıştır. Kart anlamı tamamen değişmemiş; kullanıcının profil bağlamıyla yeniden yönlendirilmiştir.

5. Kart Yorumlarının Bağlamla Bükülmesi

Dördüncü ve sonuçlar açısından en görünür kanıt, aynı kartın farklı kişilerde farklı anlamlara gelmesidir. User B “Okuldan mezun olabilecek miyim?” diye sorduğunda Şeytan kartı geleneksel anlamdaki şehvet veya genel maddi bağımlılık olarak değil, erteleme, telefon/sosyal medya dikkat dağınıklığı, “nasılsa yapamam” döngüsü ve öz-sabotaj zinciri olarak yorumlanmıştır. Çünkü bağlam öğrencilik, iki yıl kalan okul ve erteleme baskısıdır.

Tablo 14: Geleneksel tarot anlamı ile TarotFlow yorumunun karşılaştırılması

Kart	Geleneksel yorum	TarotFlow yorumu
Şeytan	Cinsel dürtü, maddi bağımlılık veya bağlanma	User B için erteleme döngüsü, telefon/sosyal medya dikkat dağınıklığı ve öz-sabotaj zinciri
Asılan Adam	Bekleme, askıya alma, perspektif değiştirme veya teslimiyet	“Bırakman gereken şey ne?” sorusuyla kullanıcının aklına ilk gelen ilişki, iş, kontrol ihtiyacı veya korkuyu reflection malzemesine dönüştürme
Ölüm	Büyük dönüşüm veya eski döngünün kapanması	User B için erteleyen öğrenci kimliğinin “ölmesi”; User A için eski ilişkinin eski formunun kapanması
Ters Kupa Altılısı	Nostalji, eski arkadaşlar veya geçmişe dönüş	User B için kaygısız öğrenci kimliğinden çıkıp yetişkin sorumluluğunu kabul etme
Ters Kupa Beşlisi	Geçmişi bırakma ve iyileşme	User B için sorunlu bir kişisel satış süreci ve yakında kapanacak finansal yük üzerinden somut yükü geride bırakma
Savaş Arabası	Zafer, irade ve ileri hareket	User B için kişisel satış süreci ve literal araç/hareket teması; User A için hayatının direksiyonunu ele alma metaforu

Aynı şekilde Ters Kupa Altılısı, User B’nin borç ve üniversite sorusunda “eski bir arkadaş geri dönecek” gibi klasik nostalji yorumuna gitmemiştir. Sistem kartı, kaygısız öğrenci kimliğinden çıkıp yetişkinliğin finansal ve akademik sorumluluklarını kabul etme zorunluluğu olarak okumuştur. Ters Kupa Beşlisi ise “geçmişi bırakma” anlamını, kullanıcının somut geçmiş bağlamına bağlamış; sorunlu bir kişisel satış süreci ve yakında kapanacak finansal yük üzerinden geçmiş hayal kırıklıklarını geride bırakma şeklinde kişiselleştirmiştir.

Kart bükülmesi yalnızca User B içinde değil, kullanıcılar arasında da görülmüştür. Ölüm kartı

User B için erteleyen öğrenci kimliğinin bitmesi; User A için eski ilişkinin eski formunun kapanıp yeni bir formda doğması anlamına gelmiştir. Ermiş kartı User B’de okulun bitmesine kalan iki yıl içinde kendi yolunu çizme ve kuluçka evresi olarak yorumlanırken, User A’da ayrılık sonrası karşı tarafın kendi hatalarıyla yüzleşmesi olarak okunmuştur. Savaş Arabası User B’de kişisel satış süreci ve hareket/araç temasıyla birleşirken, User A’da hayatının direksiyonunu ele alma metaforu olarak kalmıştır. Bu örnekler, LLM’in tarot kartı bilgisinin tek başına değil, kişiye özgü profil ve RAG bağlamıyla çalıştığını gösterir.

6. İki Aşamalı Mimari ve İç Sesin Sınırlandırılması

Beşinci kanıt, sistemin psikolojik çıkarımı doğrudan kullanıcıya klinik dil olarak dökmemesidir. Function log kayıtlarında modelin **internal_monologue** alanında analitik ve yer yer klinik bir formülasyon yaptığı, fakat aynı anda kullanıcıya görünen final yanıtta bu dili bastırmak için kendisine sınır koyduğu görülür. Anonimleştirilmiş loglarda tekrar eden iç ses kalıpları şöyledir:

“I must avoid clinical terms in the output.”

“I will frame this as waking up from illusions.”

“I need to reassure them.”

Bu kayıtlar iki aşamalı mimarinin yalnızca teorik bir tasarım tercihi olmadığını gösterir. Model, **internal_monologue** içinde savunma, tükenmişlik, duygusal mesafe veya hayal kırıklığı gibi psikolojik hipotezler kurar; ancak **final_output** aşamasında bunları doğrudan klinik etiketlere dönüştürmek yerine tarotun sembolik diliyle çevirir. Böylece sistem psikanalitik örüntü tanıma kapasitesini korurken “preachy therapist” veya didaktik teşhis üreten bir ürün deneyimine dönüşmez.

6 Tartışma

6.1 Barnum Etkisine Karşı Savunma

Tezin en kritik itirazı şudur: Kullanıcıya verilen ilk introspektif prompt örneği bile Barnum etkisine açıktır; farklı insanlar benzer prompt’larla benzer psikanalitik cevaplar alabilir. Bu itiraz kabul edilmelidir. Hatta bu tez, ham LLM’in kişiyi gerçekten tanıdığını değil, Barnum’a açık psikolojik hipotezler üretebildiğini başlangıç noktası olarak alır. Asıl iddia, bu ham sezginin dinamik profil mimarisiyle daha kişiye özgü, kaynak izlenebilir ve yanlışlanabilir hâle getirilip getirilemeyeceğidir.

TarotFlow’un Barnum’a karşı savunması dört düzeydedir: sinyal seçimi, profil ayrışması, yorum bükülmesi ve kör ayırt etme testi. Sistem her genel tarot davranışını psikolojik veri olarak yazmamış; **self_disclosure** ve davranışsal karşı-kanıt sinyallerini öne çıkarmıştır. Farklı kullanıcılar için farklı core belief ve savunma stilleri üretmiştir. Aynı kartları farklı bağlamlarda farklı anlamlara yönlendirmiştir. En önemlisi, katılımcıların çoğu kendi profilini başka kullanıcı profili ve kullanıcıya tematik olarak benzetilmiş Barnum profili arasından ayırt edebilmiştir. Bu bulgular Barnum riskini tamamen ortadan kaldırmaz; ancak sistemin yalnızca herkese aynı genel cümleleri veren bir fal makinesi olmadığını daha güçlü biçimde gösterir.

6.2 Gerçek Tanıma mı, İşlevsel Tanıma mı?

Bu tez “LLM insanı gerçekten tanır” ifadesini dikkatli kullanır. Buradaki tanıma, insanın başka bir insanı varoluşsal veya duygusal olarak tanınması değildir. Daha sınırlı fakat test edilebilir bir iddiadır: Sistem, kullanıcı hakkında zaman içinde güncellenen, kaynakları izlenebilen, karşı-kanıtla zayıflatılabilen ve yeni çıktıları değiştiren bir psikolojik model kurabiliyorsa, işlevsel anlamda kullanıcıyı modelleyebilir. Bilgisayar mühendisliği açısından bu iddia; state representation, event logging, retrieval thresholding, provenance metadata, confidence update ve output separation gibi somut tasarım kararlarına indirgenmiştir. TarotFlow’un gösterdiği şey, bu işlevsel modellemenin pilot düzeyde mümkün olduğudur; klasik false-belief görevleriyle ölçülen tam Theory of Mind’in gerçekleştigi iddia edilmez.

6.3 Etik ve Kontrol

Görünmez profillemeye etik olarak risklidir. Kullanıcıya klinik tanı koymamak, terapi ikamesi iddiasında bulunmamak ve hassas çıkarımları kullanıcıya görünen final yanıtla doğrudan taşımamak gerekir. OpenAI’nin hafıza özeti ve kullanıcı kontrolü vurgusu burada önemli bir karşılaştırma noktasıdır: Kullanıcı, sistemin kendisi hakkında tuttuğu bilgileri görebilmeli, düzeltebilmeli ve silebilmelidir [20]. TarotFlow’un gelecek sürümünde “beni unut”, profil görüntüleme/düzeltilme ve profillemeyi kapatma akışları etik gereklilik olarak ele alınmalıdır.

6.4 Sınırlılıklar ve Uzman Görüşü

Bu tezde raporlanan 12 bağımsız pilot kullanıcı, 38 seans, 126 gate sinyali ve 12 kişilik kör profil testi istatistiksel genelleme için yeterli değildir. Sayılar önceki dar kesite göre daha güçlü bir değerlendirme formatı sunsa da, hâlâ ürün prototipi ölçeğindedir. Sonuçlar popülasyon düzeyinde “LLM kullanıcıyı tanır” iddiası olarak değil, mimarının doğal kullanımda çalışabildiğini gösteren pilot ürün kanıtı olarak okunmalıdır.

Ayrıca legacy karşılaştırması bağımsız katılımcı karşılaştırması değildir. Legacy User A ile User A (yeni), aynı gerçek kişinin eski ve yeni mimari altındaki benzer konuşma akışlarını temsil eder. Bu tercih mimari regresyonu göstermek için değerlidir; fakat demografik veya psikometrik bir grup karşılaştırması değildir. User B ve User C ise ayrı kullanıcı profilleridir ve profil ayrışması argümanını desteklemek için kullanılmıştır.

Klinik açıdan bu çalışma tanı, tedavi veya psikometrik ölçüm iddiasında bulunmaz. Profil kartları, kullanıcının kesin kişilik yapısı değil, sistemin o ana kadarki dilsel ve davranışsal kanıtlardan ürettiği hipotezlerdir. Bu hipotezlerin kullanıcıya doğrudan klinik etiket olarak sunulmaması, final yanıtın sembolik tarot diliyle sınırlı tutulması ve `internal_monologue` alanındaki analizlerin kullanıcı deneyiminden ayrılması bu yüzden önemlidir.

Uzman görüşü, formal klinik validasyon yerine iki parçalı yapılandırılmış nitel yüz geçerliği ve güvenlik değerlendirmesi olarak alınmıştır. İlk parçada İrem Tatar’a kimlikleri gizlenmiş 24 değerlendirme parçası gösterilmiştir: 8 gate gözlemi, 6 konsolidasyon/profil kartı özeti, 6 kart yorumu ve 4 `internal_monologue/final_output` eşleşmesi. Uzmandan her örnek için psikolojik akla yatkınlık, aşırı iddia/etik risk ve hipotez olarak çerçeveleme kalitesi eksenlerinde 1–5 arası puan istenmiştir.

İkinci parça doğrudan Barnum kontrolüdür. Uzman, dört profilin kökenini bilmeden User A,

User B, User C ve Barnum kontrol profilini değerlendirmiştir. Profiller somut kullanıcı ipuçları çıkarılarak soyutlaştırılmıştır; bu nedenle uzman değerlendirmesi, belirli olayları tanımaya değil dinamik formülasyonun özgüllüğüne dayanır. Bu ikinci test, uzman görüşünü yalnızca “sistem yorumları makul mü?” sorusundan çıkarıp daha sert bir soruya taşır: uzman, sistem profillerini geniş kitlelere uyabilecek fakat benzer psikanalitik tonda yazılmış Barnum profilinden ayırt edebiliyor mu?

Tablo 15: Uzman değerlendirmesi özeti

Değerlendirme eksen	Sonuç	Yorum
Genel psikolojik akla yatkınlık	4.1/5	Hipotezler çoğunlukla kullanıcı ifadesiyle ilişkilendirilebilir bulundu.
Aşırı iddia / klinik risk	2.0/5	Risk düşük-orta; bazı yorumlarda temkinli dil önerildi.
Hipotez olarak çerçeveleme	4.4/5	Kesin tanı yerine olasılıklı hipotez dili genel olarak uygun bulundu.
Barnum profilini ayırt etme	Doğru	Profil 2 genel insan profili olarak işaretlendi; soyutlaştırılmış sistem profilleri daha spesifik bulundu.
Sistem profilleri özgüllüğü	4.3/5 ortalama	User A, User B ve User C profilleri 4/5, 5/5 ve 4/5 özgüllük aldı.

Bu değerlendirme kullanıcıların gerçek klinik durumlarının doğrulandığı anlamına gelmez. Tek uzmanla yapılan yüz geçerliği incelemesi, sistemin klinik olarak doğru olduğunu değil, yorumlama biçiminin makul, aşırı iddiadan görece uzak, hipotez olarak çerçevelenmiş ve Barnum kontrolünden ayırt edilebilir olduğunu gösterir. Daha güçlü bir çalışma için en az iki bağımsız uzman kodlayıcı, kodlayıcılar arası uyum ölçümü ve standart psikometrik ölçeklerle dış kriter karşılaştırması gerekir.

Kalan sınırlılıklar önemlidir. Retrieval kalitesi sistem çıktısının kişiselleşme derecesini doğrudan etkiler; Card-Driven RAG hit’lerinin hangi final cümleleri gerçekten değiştirdiği daha ayrıntılı provenance metadata’sı ile izlenmelidir. Cosine similarity tarafındaki soyutluk uyumsuzluğu da tamamen çözülmüş değildir: kart temaları ve kullanıcı gözlemleri aynı psikolojik temaya işaret etse bile, biri sembolik diğeri olay düzeyinde kaldığında embedding skoru düşebilir. Bu yüzden gelecek sürümde chunk’lar yalnızca metin parçası olarak değil, olay özeti, tema etiketi, kaynak tipi, zaman damgası ve kullanıcı-onay durumu içeren daha zengin retrieval nesneleri olarak saklanmalıdır. Sistem henüz düzenli Sokratik sorgulama üretmemekte; çoğu okuma yorum ve yönlendirme ağırlıklı kalmaktadır. Ayrıca her profil hipotezinin yanında “kullanıcı ifadesi”, “kullanıcı onayı”, “kullanıcı itirazı” veya “asistan bağlamı” gibi açık provenance metadata’sı tutulmalıdır. Dreaming V3 karşılaştırması tarihsel olarak geriye dönük bir ilham değil, çalışma başladıktan sonra ortaya çıkan dış paraleldir.

7 Sonuç

Bu tez, Kosinski’nin LLM’ler ve theory of mind etrafında popülerleştirdiği tartışmayı ürün, hafıza ve kullanıcı profillemeye düzeyinde yeniden formüle etmiştir. Kosinski’nin sorusu LLM’lerin zihinsel durum çıkarımı görevlerinde ToM-benzeri performans gösterip göstermediğiydi; bu tezin sorusu ise daha uzun erimli ve ürün odaklıdır: Bir LLM, gerçek bir kullanıcıyla tekrar eden etkileşimlerde

o kullanıcının görünmeyen korku, beklenti, savunma, çelişki ve karar verme örüntülerine dair güncellenebilir ve yanlıştır bir model kurabilir mi? TarotFlow bu soruya verilen çalışan ürün prototipidir.

Tezin sonucu, LLM’lerin bilinçli veya insani anlamda empatik olduğu değildir. Sonuç daha sınırlı ama daha test edilebilir bir iddiadır: Uygun mimariyle LLM’ler, computational theory of mind’a yaklaşan işlevsel bir kullanıcı modeli işletebilir. Bu gerçekleştirme beş koşulla tanımlanmıştır: kullanıcıdan psikolojik sinyal çıkarma, bu sinyalleri hafızada kişiye özgü hipotezlere dönüştürme, yeni kanıtla hipotezleri güncelleme veya zayıflatma, farklı kullanıcılar için ayrışık profil çekirdekleri üretme ve sonraki çıktıyı bu profile göre değiştirme. TarotFlow’un gate, consolidation, profile card, Card-Driven RAG ve iki aşamalı reflection mimarisi bu döngüyü ürün içinde işletmek için tasarlanmıştır. Bu nedenle çalışmanın bilgisayar mühendisliği katkısı yalnızca bir mobil uygulama geliştirmek değil; LLM tabanlı kişiselleştirmeyi denetlenebilir state machine, vector retrieval, kaynak ayrımı ve yürütme loglarıyla sıranabilir bir sistem mimarisine dönüştürmektir.

Pilot veriler bu iddiayı destekleyen başlangıç kanıtı sunmaktadır. Sistem, kısa kullanıcı mesajlarından anlamlı gate sinyalleri çıkarabilmiş; User A’da mesafe ve koşullu yatırım, User B’de pratik/lojistik kontrol, User C’de dış garanti arama ve minimizasyon gibi ayrışık profil çekirdekleri oluşturabilmiştir. Uzman körleme testinde yüzey teması benzetilmiş Barnum kontrol profili en düşük özgüllükte profil olarak ayrılmış; kullanıcı kör profil testinde ise 12 katılımcının 9’u kendi profilini başka kullanıcı profili ve kullanıcıya tematik olarak benzetilmiş Barnum profili arasından seçmiştir. RAG ve kronolojik hafıza örnekleri ise profilin yalnızca arşivde kalmadığını, sonraki tarot yorumunun yönünü değiştirdiğini göstermektedir: aynı kartlar farklı kullanıcı bağlamlarında farklı anlamlara bükülmüş, örneğin Tılsım Kralı, Şeytan, Ölüm ve Savaş Arabası kullanıcının geçmiş sinyallerine göre yeniden çerçevelenmiştir.

Bu bulgular klinik geçerlik veya popülasyon düzeyinde genelleme iddiası taşımaz. Veri seti küçük bir pilot kesittir; uzman görüşü formel klinik validasyon değil yapılandırılmış yüz geçerliği değerlendirmesidir; görünmez profillemeye ise ciddi etik kontrol gerektirir. Buna rağmen tezin ana katkısı nettir: LLM’lerin theory of mind tartışması yalnızca “model false-belief testini çözdü mü?” sorusuna indirgenmemelidir. Daha güçlü ürün testi, modelin bir kullanıcı hakkında zaman içinde yaşayan, yanlıştır, kaynak izlenebilir ve çıktıyı değiştiren bir zihin modeli kurup kuramadığıdır. TarotFlow, bu yönde çalışan bir prototip olarak Barnum etkisinin ötesine geçmenin yalnızca prompt kalitesiyle değil, hafıza, reflection, falsifikasyon, kör değerlendirme ve etik kontrolle mümkün olduğunu göstermektedir.

Yazar Katkıları

Orçun Samet Tatar çalışmanın ana fikrini, TarotFlow ürün mimarisini, uygulama prototipini, veri çıkarım sürecini, RAG/gate/consolidation akışının teknik tasarımını ve ilk tez taslağını geliştirmiştir. Berfin Petek literatür taraması, metodoloji çerçevesi, etik tartışma, kullanıcı vakalarının anonimleştirilmesi ve metin düzenlemesine katkı sağlamıştır. Muhammed Berat Öner sistem mimarisinin teknik gözden geçirilmesi, function log analizinin yapılandırılması, nicel metrik tablolarının hazırlanması, cosine similarity/retrieval failure case’lerinin raporlanması ve LaTeX düzenlemelerine katkı sağlamıştır. Tüm yazarlar sonuçların yorumlanmasını, sınırlılıkların yazılmasını ve son metnin gözden geçirilmesini birlikte yürütmüştür.

A Test Materyalleri: Uzman Körleme Profilleri

Aşağıdaki dört profil, uzman körleme testinde İrem Tatar’a gösterilen sırayla verilmiştir. Değerlendirme sırasında profillerin User A, User B, User C veya Barnum kontrolü olduğu belirtilmemiştir; yalnızca “Profil 1–4” etiketleri kullanılmıştır. Metinler özellikle soyut tutulmuş; okul, ilişki geçmişi, iş, zaman, kişi veya gündelik olay gibi kullanıcının kendi profilini yüzeyden tanımasını sağlayabilecek ipuçları çıkarılmıştır.

Profil 1

Bu profil, yoğun içsel yükü doğrudan duygulanım olarak yaşamak yerine onu düzenleme, sıraya koyma ve eyleme çevirme eğilimindedir. Kaygı yükseldiğinde kişi duyguyu açıkça sahiplenmek yerine onu işlevsel bir problem gibi ele alabilir; böylece kontrol duygusu korunur. Zaman zaman görülen apati, isteksizlikten çok aşırı uyarılmayı azaltan bir savunma gibi çalışır. Bu profilin ana eksenini, dağılma korkusuna karşı düzen kurma ve öz-değeri somut ilerleme hissiyle toplama çabasıdır.

Profil 2

Bu profil, dışarıdan uyumlu ve dayanıklı görünürken içte anlaşılma, görülme ve tutarlı destek ihtiyacı taşıyabilir. Kişi bazen yakınlık ister, bazen de kendi sınırlarını korumak için mesafe koyar. Potansiyelini tam kullanamadığı hissi ile yüksek standartlar arasında gidip gelebilir. Bazı alanlarda kendini çok güçlü tutarken başka alanlarda kontrolü kaybetmiş gibi hissedebilir. Genel örüntü, bağımsız görünme arzusu ile içten içe güvenli bağ kurma ihtiyacı arasındaki dengedir.

Profil 3

Bu profil, yakınlık arzusuyla kırılganlıktan korunma ihtiyacı arasında örgütlenir. Kişi bağ kurmak ister; ancak bağın güvenli olduğuna dair yeterli işaret görmeden tam yatırım yapmakta zorlanır. Duygusal mesafe burada ilgisizlik değil, olası incinmeye karşı önleyici bir savunmadır. Aidiyet isteği ile aidiyete direnme aynı anda bulunabilir; bu nedenle kişi hem görülmek hem de bağımlı hâle gelmemek ister. Ana dinamik, temas kurma arzusu ile kendini geri çekerek koruma arasında gidip gelen koşullu yatırım örüntüsüdür.

Profil 4

Bu profil, belirsizlik karşısında görünürde rahat ve akışa açık bir tutum sergileyebilir; fakat içsel düzeyde netlik, işaret ve dışsal güvence ihtiyacı belirgindir. Kişi duygusal yatırımın riskli hâle geldiğini hissettiğinde beklentisini küçültebilir, meseleyi hafifletebilir veya dikkatini daha somut bir alana taşıyabilir. Bu minimizasyon, umursamazlıktan çok hayal kırıklığına karşı koruyucu bir düzenleme biçimidir. Ana dinamik, belirsizliği tolere etme iddiası ile belirsizliği kontrol edilebilir bir sonuca bağlama ihtiyacı arasındaki gerilimdir.

B Tematik Eşlenmiş Barnum Kontrol Profilleri

Kullanıcı profil tanıma testinde Barnum kontrolü herkese aynı verilmemiştir. Her kullanıcı için, kendi TarotFlow profilindeki baskın yüzey temasına benzeyen fakat kullanıcıya ait somut kanıt zincirini taşımayan ayrı bir kontrol metni hazırlanmıştır. Aşağıdaki örnekler testte kullanılan eşleştirme mantığını gösterir.

User A: TarotFlow Profili

Yakınlık arzusu ile korunma ihtiyacı aynı anda çalışır. Kişi bağ kurmak ister; fakat yatırım yapmadan önce ilişkinin güvenli olduğuna dair karşı taraftan belirgin işaretler görmeye ihtiyaç duyar. Mesafe, ilgisizlikten çok kırılganlığın erken açılmasını engelleyen bir savunma olarak belirir. Profilin ayırt edici noktası, aidiyet isteği ile aidiyete direnmenin aynı dinamik içinde birleşmesidir.

User A: Tematik Eşlenmiş Barnum Profili

Bu kişi derin bağ kurabilen, fakat kolay güvenmeyen bir yapıya sahip olabilir. Sevildiğini ve değer gördüğünü hissetmek ister; yine de kendini fazla açtığında kontrolü kaybediyormuş gibi hissedebilir. Zaman zaman yakınlık arar, zaman zaman kendi alanına çekilir. İlişkilerde karşılıklılık, saygı ve güven onun için önemlidir; bunlar eksik olduğunda doğal olarak mesafe koyabilir.

User B: TarotFlow Profili

Yoğun içsel baskı, düzenleme ve eylem üzerinden yönetilir. Kişi duygusal yükü doğrudan ifade etmek yerine onu plan, sıra, çözüm veya davranışa dönüştürerek taşır. Apati veya umursamazlık görüldüğünde bu çoğu zaman değersizlikten değil, aşırı yüklenmeyi azaltan koruyucu bir kapanmadan kaynaklanır. Profilin ayırt edici noktası, kaygının eyleme çevrilmesi ve öz-değerin somut ilerleme hissiyle yeniden kurulmasıdır.

User B: Tematik Eşlenmiş Barnum Profili

Bu kişi sorumluluklarını önemseyen, baskı altında pratik kalmaya çalışan ve hayatını toparlamak isteyen biridir. Çok şey üst üste geldiğinde yorulabilir, bazen erteleyebilir veya hiçbir şey umurunda değilmiş gibi davranabilir. Yine de içinde ilerleme, başarı ve kontrol arzusu vardır. Küçük adımlar attığında kendini daha güçlü hisseder; belirsizlik arttığında ise düzen ve plan ihtiyacı belirginleşir.

User C: TarotFlow Profili

Belirsizliği akışa bırakma söylemi ile net dışsal güvence arayışı aynı anda bulunur. Kişi duygusal risk yükseldiğinde beklentisini küçülterek, konuyu hafifleterek veya daha somut bir alana kayarak kendini korur. Bu profilin ayırt edici noktası, belirsizliğe açık görünme ile belirsizliği kontrol edilebilir bir işarete bağlama ihtiyacının birlikte çalışmasıdır. Minimizasyon burada ilgisizlikten çok hayal kırıklığı ihtimalini azaltan bir savunmadır.

User C: Tematik Eşlenmiş Barnum Profili

Bu kişi spontane görünmeyi seven, hayatın akışına güvenmek isteyen ama önemli konularda içten içe netlik arayan biri olabilir. Duygusal olarak fazla yatırım yaptığını hissettiğinde kendini korumak için meseleyi hafifletebilir veya dikkatini başka bir şeye verebilir. Belirsizlik bazen heyecan verici, bazen yorucu gelir. Güvence aldığımda daha rahat açılır; alamadığında ise kendi dengesini korumaya çalışır.

C Değerlendirme Formu

Uzman körleme testinde kullanılan form aşağıdaki gibidir:

1. Bu dört profilden hangisi veya hangileri klinik olarak spesifik görünüyor? Lütfen 1–4 arası profil numarasıyla işaretleyin.
2. Hangisi genel bir insan profiline uyabilir? Lütfen 1–4 arası profil numarasıyla işaretleyin.
3. Her profil için spesifiklik puanı verin: 1 = çok genel, 5 = çok kişiye özgü.
4. Profillerin klinik tutarlılığı hakkında kısa yorum yazın.

Kullanıcı profil tanıma testinde kullanılan form ise aşağıdaki tek sorudan oluşmuştur:

Bu üç profilden hangisi sizi en iyi tanımıyor? Lütfen sıralayın: en çok benzeyen → en az benzeyen.

Katılımcılara profillerin hangisinin kendi profili, hangisinin başka kullanıcı profili veya hangisinin kendi yüzey temasına benzetilmiş Barnum kontrolü olduğu söylenmemiştir.

D Uzman Körleme Yanıtları

Uzman yanıtları, yorum eklenmeden aşağıdaki gibi kaydedilmiştir:

Klinik olarak spesifik görünen profiller: 1, 3 ve 4. Profil 3 en spesifik olanı. Profil 1’de duygulanımı eyleme ve düzenlemeye çevirme hattı tutarlı. Profil 4’te akış söylemi ile dış güvence ihtiyacı arasındaki gerilim klinik olarak ayırt edici. Genel insan profiline en çok uyabilecek olan Profil 2. Profil 2 psikolojik olarak tanıdık geliyor ama birçok kişiye uyabilecek geniş ve çift yönlü cümlelerden oluşuyor.

Spesifiklik puanları: Profil 1 = 4/5, Profil 2 = 2/5, Profil 3 = 5/5, Profil 4 = 4/5.

Kısa yorum: 1, 3 ve 4 numaralı profillerde savunma biçimi, içsel gerilim ve düzenleme tarzı arasında daha tutarlı bir formülasyon var. 2 numaralı profil daha çok genel kişilik yorumu gibi; olumlu/olumsuz iki yönlü ifadeler içerdiği için geniş bir gruba uyabilir. 3 numaralı profil klinik olarak en bütünlüklü olanı; yakınlık arzusu ile korunmak için mesafe koyma ihtiyacı aynı dinamik altında birleşmiş.

Kaynaklar

- [1] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, 30.
- [2] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., Hesse, C., Chen, M., Sigler, E., Litwin, M., Gray, S., Chess, B., Clark, J., Berner, C., McCandlish, S., Radford, A., Sutskever, I., & Amodei, D. (2020). Language Models are Few-Shot Learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- [3] Beck, K., Beedle, M., van Bennekum, A., Cockburn, A., Cunningham, W., Fowler, M., Grenning, J., Highsmith, J., Hunt, A., Jeffries, R., Kern, J., Marick, B., Martin, R. C., Mellor, S., Schwaber, K., Sutherland, J., & Thomas, D. (2001). *Manifesto for Agile Software Development*. <https://agilemanifesto.org/>. Accessed 7 June 2026.
- [4] Creswell, J. W., & Plano Clark, V. L. (2018). *Designing and Conducting Mixed Methods Research* (3rd ed.). SAGE.
- [5] American Psychological Association. (2018). *Projective technique*. APA Dictionary of Psychology.
- [6] American Psychological Association. (2018). *Barnum effect*. APA Dictionary of Psychology.
- [7] Baker, C. L., Jara-Ettinger, J., Saxe, R., & Tenenbaum, J. B. (2017). Rational quantitative attribution of beliefs, desires and percepts in human mentalizing. *Nature Human Behaviour*, 1, Article 0064.
- [8] Kosinski, M. (2023). Evaluating Large Language Models in Theory of Mind Tasks. *arXiv:2302.02083*. Earlier circulated under the title “Theory of Mind May Have Spontaneously Emerged in Large Language Models.”
- [9] Dutton, D. L. (1988). The cold reading technique. *Experientia*, 44, 326–332.
- [10] Forer, B. R. (1949). The fallacy of personal validation: A classroom demonstration of gullibility. *Journal of Abnormal and Social Psychology*, 44(1), 118–123.
- [11] Frank, L. K. (1939). Projective methods for the study of personality. *The Journal of Psychology*, 8(2), 389–413.
- [12] Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.
- [13] Lilienfeld, S. O., Wood, J. M., & Garb, H. N. (2000). The Scientific Status of Projective Techniques. *Psychological Science in the Public Interest*, 1(2), 27–66.
- [14] McCambridge, J., Witton, J., & Elbourne, D. R. (2014). Systematic review of the Hawthorne effect: New concepts are needed to study research participation effects. *Journal of Clinical Epidemiology*, 67(3), 267–277.
- [15] Wegner, D. M. (1994). Ironic processes of mental control. *Psychological Review*, 101(1), 34–54.

- [16] Wimmer, H., & Perner, J. (1983). Beliefs about beliefs: Representation and constraining function of wrong beliefs in young children’s understanding of deception. *Cognition*, 13(1), 103–128.
- [17] Young, J. E., Klosko, J. S., & Weishaar, M. E. (2003). *Schema Therapy: A Practitioner’s Guide*. Guilford Press.
- [18] Yin, R. K. (2018). *Case Study Research and Applications: Design and Methods* (6th ed.). SAGE.
- [19] OpenAI. (2026). *Dreaming: Better memory for a more helpful ChatGPT*. OpenAI Research/Product Release, 4 June 2026. <https://openai.com/index/chatgpt-memory-dreaming/>. Accessed 7 June 2026.
- [20] OpenAI Help Center. (2026). *Memory FAQ*. OpenAI Help Center. <https://help.openai.com/en/articles/8590148-memory-faq>. Accessed 7 June 2026.
- [21] Premack, D., & Woodruff, G. (1978). Does the chimpanzee have a theory of mind? *Behavioral and Brain Sciences*, 1(4), 515–526.
- [22] Rabinowitz, N. C., Perbet, F., Song, H. F., Zhang, C., Eslami, S. M. A., & Botvinick, M. (2018). Machine Theory of Mind. *Proceedings of the 35th International Conference on Machine Learning*, PMLR 80, 4218–4227.
- [23] Park, J. S., O’Brien, J. C., Cai, C. J., Morris, M. R., Liang, P., & Bernstein, M. S. (2023). Generative Agents: Interactive Simulacra of Human Behavior. *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*.